



**UNIVERSIDADE ESTADUAL DE SANTA CRUZ
PRO-REITORIA DE PESQUISA E PÓS-GRADUAÇÃO**

**PROGRAMA DE PÓS-GRADUAÇÃO EM MODELAGEM COMPUTACIONAL
EM CIÊNCIA E TECNOLOGIA**

FELIPE ANTUNES DOS SANTOS

**MODELAGEM DE UM SISTEMA DE VISÃO COMPUTACIONAL PARA A
CLASSIFICAÇÃO DE AMÊndoAS DE CACAU NA PROVA DE CORTE**

**ILHÉUS-BA
2019**

FELIPE ANTUNES DOS SANTOS

**MODELAGEM DE UM SISTEMA DE VISÃO
COMPUTACIONAL PARA A CLASSIFICAÇÃO DE
AMÊndoAS DE CACAU NA PROVA DE CORTE**

Dissertação apresentada ao Programa de Pós-Graduação
em Modelagem Computacional em Ciência e Tecnologia
da Universidade Estadual de Santa Cruz, como parte
das exigências para obtenção do título de Mestre em
Modelagem Computacional em Ciência e Tecnologia.

Orientador: Prof. Dr. Eduardo Silva Palmeira

Coorientador: Prof. Dr. Gildson Queiroz de Jesus

ILHÉUS-BA
2019

S237

Santos, Felipe Antunes dos
Modelagem de um sistema de visão computacional para a classificação de amêndoas de cacau na prova de corte / Felipe Antunes dos Santos. – Ilhéus, BA: UESC, 2019.
xviii, 62f. : il.

Orientador: Eduardo Silva Palmeira
Dissertação (Mestrado) – Universidade Estadual de Santa Cruz. Programa de Pós-Graduação em Modelagem Computacional em Ciência e Tecnologia.

Inclui referências.

1. Cacau. 2. Redes neurais (Computação). 3. Visão por computador. 4. Sementes – Qualidade. 5. Sementes – Testes. 6. Banco dados. I. Título.

CDD 633.74

FELIPE ANTUNES DOS SANTOS

**MODELAGEM DE UM SISTEMA DE VISÃO
COMPUTACIONAL PARA A CLASSIFICAÇÃO DE
AMÊndoAS DE CACAU NA PROVA DE CORTE**

Ilhéus-BA, 23/01/2019

Comissão Examinadora

Prof. Dr. Eduardo Silva Palmeira
UESC
(Orientador)

Prof. Dr. Paulo Eduardo Ambrósio
UESC

Prof. Dr. Benjamín René Callejas
Bedregal
UFRN

Prof. Dr. Alex Santana dos Santos
UFRB

Dedico este trabalho a minha mãe, senhora
Maria da Conceição Antunes, por ser um
exemplo de pessoa e por ter tornado esta
caminhada possível

Agradecimentos

- A minha família, especialmente à minha mãe, por todo o apoio e incentivo nesta caminhada;
- Aos meus amigos, amigas e colegas, por todos os momentos de apoio e descontração, sem os quais tornariam esta caminhada extenuante;
- Ao meu orientador, Prof. Dr. Eduardo Silva Palmeira, por ser o melhor orientador possível;
- Ao meu coorientador, Prof. Dr. Gildson Queiroz de Jesus, por também de apoiar e me guiar nesta caminhada;
- Ao Centro de Inovação do Cacau, pelo apoio e incentivo no trabalho, especialmente à Cristiano, Adriana, Samuel, Johnatan, Weslem, Laysa e Sabrina, pelas presenças, apoios e incentivos constantes;
- Aos professores doutores Marcos Eduardo Valle e Alex Santana dos Santos, pela prestatividade e colaboração nos testes com memórias associativas fuzzy.

*“Quando você pergunta ‘porquê?’, ‘e se?’ e
‘porquê não?’ você se força a explorar o que é
possível, não somente o que é.”*

Josh Linkner

MODELAGEM DE UM SISTEMA DE VISÃO COMPUTACIONAL PARA A CLASSIFICAÇÃO DE AMÊNDOAS DE CACAU NA PROVA DE CORTE

Resumo

O cacau é um fruto considerado para muitos propósitos, incluindo a fabricação de chocolate, em que as suas amêndoas são utilizadas. Sementes de cacau para a fabricação do chocolate requerem diversos testes de qualidade, regidos por instruções normativas. Um deles é o teste de corte, em que, em uma das etapas, um especialista corta um número específicos de sementes latitudinalmente com o objetivo de avaliar as características interiores, como a coloração, compartimentação e defeitos, que revelam o grau e a qualidade do processo que foi utilizado para a fermentação das amêndoas, seus sabores, potenciais substâncias danosas à saúde humana, descrevem o tipo comercial do lote analisado, além de outros aspectos. Este teste é feito manualmente e, além das imprecisões causadas pelas limitações e percepções humanas, ele é dispendioso. Neste trabalho, nós avaliamos e aplicamos técnicas e metodologias de visão computacional e redes neurais para a construção de um modelo computacional para auxiliar o especialista na etapa da prova de corte em que é feita a classificação interna das amêndoas de cacau e, como parte da pesquisa, construímos uma base de imagens de amêndoas de cacau classificadas na prova de corte.

Palavras-chave: cacau. prova de corte. redes neurais artificiais. visão computacional. classificação. base de imagens.

Abstract

Cocoa is a fruit that is used for many purposes, including chocolate fabrication in which its beans are used. Cocoa beans, for the chocolate fabrication in Brazil, requires a set of quality tests that are regulated by normative rule. One of those tests is the cut test, in which, among other steps, an expert opens a specific number of beans, in a lengthwise orientation, to infer about the interior coloration and compartmentalizing. This test is manually made, there are imprecisions, caused by human limitations and perceptions, and the test itself is very time consuming. In this work we evaluate and apply computational vision techniques and methodologies and artificial neural networks to build a computational model to help the specialists in this internal classification test and, as part of this research, we built an image dataset of cut-tested cocoa beans.

Keywords: cocoa. cut test. artificial neural network. computer vision. classification. image dataset.

Lista de figuras

Figura 1 – Tábuas utilizadas para a prova de corte, sendo a da esquerda uma vazia e a da direita uma tábua preenchida com amêndoas já cortadas	8
Figura 2 – Aproximação em amêndoas sendo analisadas na tábua da prova de corte	9
Figura 3 – Exemplo de rede PMC	11
Figura 4 – Ilustração do problema do mínimo local causado por uma taxa de aprendizado muito baixa	12
Figura 5 – Ilustração do problema do oscilação causado por uma taxa de aprendizado muito alta	12
Figura 6 – Etapas de treinamento de uma rede PMC	14
Figura 7 – Ilustração do processo de treinamento de uma PMC	14
Figura 8 – Construção de uma matriz de co-ocorrência de uma imagem com resolução de contraste de oito tons	16
Figura 9 – Diferenças visíveis entre as classes de uma amêndoia, na esquerda, uma amêndoia achatada, na direita	19
Figura 10 – A Base do protótipo para a captura das imagens para a construção do <i>dataset</i>	22
Figura 11 – Modelo bidimensional com as medidas da Base do protótipo de captura	23
Figura 12 – Topo do protótipo de captura, onde: na esquerda observamos, com a câmera posicionada e as luzes acesas, e na direita sem a câmera, uma amêndoia sendo registrada	24
Figura 13 – Modelo bidimensional com as medidas do local de posicionamento da câmera	25
Figura 14 – Modelo das lâmpadas	26
Figura 15 – Posicionamentos das lâmpadas no interior do protótipo	27
Figura 16 – Modelo de câmera digital utilizado para a construção do <i>dataset</i>	28
Figura 17 – À esquerda foi o ambiente em que os testes de corte foram efetuados e à direita foi o local onde as imagens foram registradas	29
Figura 18 – À esquerda uma amêndoia Branca Chapada do <i>dataset</i> e na direita o resultado da aplicação do primeiro passo na imagem em questão	30
Figura 19 – Duas tentativas de eliminar o plano de fundo no espaço de cores RPG, a da esquerda com o limiar muito amplo e a da direita com o limiar muito restrito	31
Figura 20 – Na esquerda está o resultado da primeira técnica e na direita o resultado da aplicação da Etapa 2 em tal imagem	32

Figura 21 – Na esquerda está o resultado da imagem binarizada na Etapa 2 e na direita o resultado depois da Etapa 3	32
Figura 22 – Na esquerda está o resultado da etapa três e na direita o resultado da aplicação dessa como máscara na imagem original, eliminando eventuais poeiras ou pedaços de outros corpos que não estão na amêndoas	33
Figura 23 – Na esquerda está a imagem resultante da quarta etapa e na direita o resultado da conversão da mesma para tons de cinza	34
Figura 24 – Esquerda Superior: a imagem resultante da Etapa 4; direita superior: a cama vermelha isolada de tal imagem; esquerda inferior: a cama verde isolada; e direita inferior: a cama azul isolada	35
Figura 25 – Ilustração da primeira inversão de imagem, para a amêndoas Branca Chapada 34, no segundo método	36
Figura 26 – Ilustração da primeira inversão de imagem, para a amêndoas Branca Chapada 40, no segundo método	37
Figura 27 – Ilustração da segunda aplicação do método baseado em watershed, para eliminação de danos interiores, na amêndoas 34	37
Figura 28 – Ilustração da segunda aplicação do método baseado em watershed, para eliminação de danos interiores, na amêndoas 40	38
Figura 29 – Ilustração da segunda inversão durante o segundo método, aplicada na amêndoas Branca Chapada 34	38
Figura 30 – A esquerda a máscara do Método A aplicado e na direita a do Método B, resultando em uma amêndoas menos danificada	39
Figura 31 – Parte do plano de fundo recuperado em uma amêndoas com uma fissura	39
Figura 32 – Ilustração do funcionamento do algoritmo para a extração do perímetro das amêndoas	41
Figura 33 – Amêndoas como apresentadas no <i>dataset</i> original, uma Branca chapada, na esquerda, e uma Branca Compartimentada na direita.	45
Figura 34 – Exemplo de amêndoas do <i>dataset</i> processado pelo método descrito na Seção 4.2.1. Uma sementes Branca Chapada na esquerda e uma branca compartimentada na direita.	46
Figura 35 – <i>Dataset</i> construído com o Método B, descrito na seção 4.2.2. Uma amêndoas Branca Chapada na esquerda e uma Branca Compartimentada na direita.	47
Figura 36 – Exemplos de imagens, para as amêndoas do <i>dataset</i> da Seção 5.1.2.1, recortadas no menor retângulo possível que as caibam.	48
Figura 37 – Sementes do método 1 recortadas e centralizadas	49
Figura 38 – Amêndoas, do <i>dataset</i> construído com o segundo método, recortadas e centralizadas no menor retângulo individual que as caibam	50

Figura 39 – Amêndoas, do segundo método, centralizadas no retângulo construído a partir da maior largura e maior altura de todas as sementes	51
Figura 40 – Topologia Final da Rede MLP	53
Figura 41 – Estudo de Acurácia e Definição de Neurônios da Primeira Camada .	53
Figura 42 – Estudo de Acurácia e Definição de Neurônios da Segunda Camada .	54

Lista de tabelas

Tabela 1 – Tolerância de defeitos dos tipos de lotes de amêndoas de cacau	10
Tabela 2 – Equações para o cálculo dos descritores de textura de Haralick	18
Tabela 3 – Especificações das lâmpadas utilizadas	26
Tabela 4 – Algumas especificações da câmera utilizada	28
Tabela 5 – Acurárias resultantes das combinações das características das ima- gens com a rede MLP	55

Lista de algoritmos

1	Algoritmo para o cálculo das médias das camadas de cores das amêndoas	40
2	Algoritmo para o cálculo da área da amêndoas	41
3	Algoritmo principal para o cálculo do perímetro externo da amêndoas . .	42

Lista de abreviaturas e siglas

CIC	Centro de Inovação do Cacau
UESC	Universidade Estadual de Santa Cruz
CIELAB	Espaço de cor CIE L*a*b
RGB	Espaço de cor Vermelho, Verde e Azul (Red, Green and Blue)
HSV	Espaço de cor Matiz, Saturação e Valor (Hue, Saturation and Value)
ANN, RNA	Rede Neural Artificial (Artificial Neural Network)
PMC, MLP	Rede Perceptron Multicamada (Multilayer Perceptron)
GLCM	Matriz de coocorrência (Grayscale Co-occurrence Matrix)
LED	Diodo Emissor de Luz (Light Emitting Diode)
JPG	Joint Photographic Experts Group
GS	Grayscale
Pe	Perímetro
Ar	Área
14H	Os resultados das quatorze fórmulas para a extração de descritores de textura de Haralick
RGB Means	Médias de cores dos canais RGB
GS Mean	Média de cor da imagem em tons de cinza
HX	Entropia de p_x
<td>Entropia de p_y</td>	Entropia de p_y
HXY	Equação 1
HXY1	Equação 2
HXY2	Equação 3
Q	Equação 4

Lista de símbolos

η Taxa de Aprendizagem

w, ω Peso Sináptico

θ Limiar de Ativação

μ_x Desvio médio de p_x

μ_y Desvio médio de p_y

σ_x Desvio padrão de p_x

σ_y Desvio padrão de p_y

Sumário

1 – Introdução	1
2 – Revisão de literatura	3
2.1 Visão Computacional e Classificação	3
3 – Fundamentação Teórica	8
3.1 Prova de Corte	8
3.2 Redes Neurais	10
3.3 Descritores de Características de Imagens	15
3.3.1 Descritores de Texturas de Haralick	15
3.3.2 Descritores de Estrutura	18
3.3.3 Descritores de Cores	19
4 – Materiais e Métodos	21
4.1 Base de Imagens de Amêndoas de Cacau Classificadas na Prova de Corte	21
4.1.1 Protótipo para Captura	21
4.1.2 Câmera e Configurações	27
4.1.3 Processo de Aquisição	28
4.2 Processamento de Imagens	29
4.2.1 Método A - Remoção de Não-Amêndoas	29
4.2.1.1 Etapa 1 - Remoção do Plano de Fundo	30
4.2.1.2 Etapa 2 - Binarização da Imagem	31
4.2.1.3 Etapa 3 - Remoção de Não-Amêndoas	32
4.2.1.4 Etapa 4 - Aplicação de Máscara	33
4.2.1.5 Etapa 5 - Conversão para Tons de Cinza	33
4.2.1.6 Etapa 6 - Extração das Camadas de Cores	34
4.2.2 Método B - Recuperação de Amêndoas	35
4.2.2.1 Etapa 4 - Inversão da Imagem Binarizada	36
4.2.2.2 Etapa 5 - Recuperação de Danos Internos	37
4.2.2.3 Etapa 6 - Re-inversão da Imagem	38
4.2.2.4 Etapa 7 - Aplicação de Máscara	39
4.3 Descritores para a Classificação de Amêndoas de Cacau	40
5 – Resultados e Discussões	43
5.1 <i>Dataset</i> de imagens de cacau classificadas na prova de corte	43
5.1.1 <i>Dataset</i> Original	44
5.1.2 <i>Dataset</i> Sem Plano de Fundo	45

5.1.2.1	Versão 1 - Processado com Método A	45
5.1.2.2	Versão 2 - Processado com Método B	46
5.1.3	<i>Dataset Com as Amêndoas Centralizadas e Enquadradadas</i>	47
5.1.3.1	Versão 1 - Processado com Método A e Enquadrado Individualmente	47
5.1.3.2	Versão 2 - Processado com Método A e Enquadrado Uniformemente	48
5.1.3.3	Versão 3 - Processado com Método B e Enquadrado Individualmente	49
5.1.3.4	Versão 4 - Processado com Método B e Enquadrado Uniformemente	50
5.2	Modelo para a Classificação das Amêndoas	51
5.2.1	Configuração de Uma Rede Perceptron Multicamada para a classificação	52
5.2.1.1	Primeira Camada da MLP	53
5.2.1.2	Segunda Camada da MLP	53
5.2.2	Combinações de descritores de cor, estrutura e textura para a análise	54
5.3	Modelo Final para a Classificação	56
6 – Considerações finais	57
6.1	Principais Contribuições	57
6.2	Trabalhos Futuros	57
Referências	59

1 Introdução

Cacau é um fruto cuja suas primeiras aparições e usos datam do tempo pré-histórico e, atualmente, é consumido e utilizado na produção de diversos produtos em várias partes do mundo. Nesse contexto, as amêndoas de cacau podem ser utilizadas em diversas produções, incluindo para a fabricação do chocolate ([CATSBERG; DOMMELEN, 1990; WOOD; LASS, 2008](#)).

A medida que a história avançou, o processo de produção de chocolate também evoluiu, incluindo agora, através de normas regulativas ao redor do mundo, a necessidade de se fazer vários testes de classificação e caracterização nas amêndoas de cacau para os seus usos e comercializações. Nesse contexto, o Teste de Corte é aquele no qual, dentre outros processos, uma quantidade de amêndoas é retirada como amostra de todo um lote de produção e especialistas cortam centenas destas amêndoas, latitudinalmente, para inferir sobre a compartimentação, cor, defeitos e outras características ([WOOD; LASS, 2008; AGRICULTURA, 2008](#)).

O Teste de Corte (ou prova de corte) é importante devido às características internas, como a cor e compartimentação, estarem relacionadas com o sabor e a qualidade das amêndoas cujo lote foi analisado e, além disso, é nele que identifica-se a presença de substâncias nocivas ao ser humano, prevenindo assim o processamento de amêndoas que representam um real risco à saúde das pessoas. Em relação às cores internas e compartimentações, descrições linguísticas como Violeta, Parcialmente Violeta, Marrom, Branco, Bem Compartimentado, Não-Compartimentado e Ardósia são utilizadas ([SULAIMAN; YANG, 2015; VALLE, 2012](#)).

Aqui emerge um problema natural de quando se trabalha com classificações baseadas em características linguísticas, como variabilidade e imprecisão. Por exemplo, existem diversas tonalidades de violeta, diversas de marrom e das outras cores, de modo que a avaliação de uma semente como uma destas pode levantar o questionamento de quanto seria parcialmente violeta e parcialmente marrom e a partir de que ponto a semente seria só marrom; assim como existe incerteza quanto à quantificação de bem compartimentado ou pouco compartimentado, o que gera padrões que podem destoar de avaliador a avaliador. Além disso, o processo da prova de corte é dispendioso, de modo que um especialista pode levar mais de uma hora para classificar uma amostra ([NEITZ et al., 2002; KIM et al., 2009](#)).

Em vista das imprecisões citadas anteriormente, e de outras condições que podem influenciar a avaliação da prova de corte, como a fatiga, motivos pessoais e mudança de percepção de cores, levantou-se o questionamento sobre a possibilidade de

criar um modelo computacional, baseado no processamento de imagens digitais, para auxiliar ao especialista na execução do Teste de Corte ([SAVAKAR, 2012](#)).

Observando-se pesquisas similares na literatura, foi-se percebido que as aplicações de redes neurais *perceptron* multicamadas para classificações de imagens digitais, tendo-se como argumentos para a rede as características descritivas extraídas das imagens, ofereceram resultados satisfatórios para diversos autores. Desta forma, essa pesquisa objetiva a modelagem de um sistema de visão computacional para a classificação de amêndoas de cacau na prova de corte, se utilizando de redes neurais *perceptron* multicamadas e da extração de características de um banco de imagens composto por sementes de cacau classificadas na prova de corte.

Para tanto, no Capítulo [2](#) serão analisados diversas pesquisas e aplicações em que redes neurais e extração de características de imagens digitais foram utilizadas para a classificação e caracterização de produtos de origem natural. A seguir, o Capítulo [3](#) traz uma breve visão do arcabouço teórico de redes neurais artificiais (ANN), das características que foram extraídas das imagens pertencentes à base criada nesta pesquisa e também os métodos e técnicas utilizadas para a segmentação, processamento e extração das características em questão. Além disso, no Capítulo [4](#) apresenta-se uma padronização do processo de captura de imagens através da elaboração de um protótipo feito para esse propósito e uma base de imagens de amêndoas de cacau classificadas na prova do corte, produzida com auxílio de especialistas do Centro de Inovação do Cacau (CIC). Já o Capítulo [5](#) é dedicado a apresentação das diversas versões desta base de imagens, com diferentes tipos de processamentos, produzidas para ampliar o leque de possibilidades de aplicações da mesma, além dos resultados e análises das precisões obtidas durante esta pesquisa. Por fim, o Capítulo [6](#) traz uma discussão a respeito possibilidades de trabalhos futuros e a conclusão desta pesquisa.

2 Revisão de literatura

Neste capítulo serão apresentados diversas produções científicas nas áreas de processamento de imagens, extração de características, redes neurais artificiais, classificação de imagens e espaços de cores. A intenção é angariar arcabouço prático-teórico-científico para a execução de uma pesquisa de qualidade e relevância para com o cenário atual da área. Suplementarmente, para um melhor entendimento dos conceitos que serão explorados nos tópicos seguintes, é apresentada a seguinte definição do que é uma imagem digital:

Uma imagem pode ser definida como uma função bi-dimensional $f(x, y)$, onde x e y são coordenadas espaciais e a amplitude de f em qualquer coordenada (x, y) é chamada de intensidade ou nível de cinza da imagem naquele ponto. Quando x , y e os valores de amplitude são todos finitos e discretos, chamamos a imagem de imagem digital. ([GONZALEZ; WOODS, 2002](#), p. 1, tradução nossa).

2.1 Visão Computacional e Classificação

A visão computacional é um campo que visa o desenvolvimento e a aplicação de teorias, tecnologias, técnicas e métodos para a construção de sistemas artificiais capazes de obter informações de dados multi-dimensionais, principalmente as imagens digitais. O avanço das tecnologias e das teorias da área possibilitaram o aparecimento de diversos estudos que apresentam ou propõe sistemas de classificações para diversos produtos de origem agrícola, como o café, trigo, cacau e arroz, sendo que vários destes sistemas se utilizam de características extraídas de imagens digitais e redes neurais artificiais para classificá-las ([MARENCONI; STRINGHINI, 2009](#); [BIANCHI; REALI-COSTA, 2000](#)).

Observa-se na literatura inúmeros trabalhos sobre visão computacional e o uso de descritores de características de imagens, como [Nandi et al. \(2014\)](#), que apresenta um sistema de visão computacional para a classificação de mangas. No estudo em questão são utilizadas diversas técnicas de processamento de imagens, como métodos de *thresholding* de cores e binarização para a análise de defeitos na casca dos frutos, além da avaliação da maturidade das mesmas, inferida através da observação de distribuição de cores na imagem e de detecção de contorno, assim como de outras características.

Já em [Savakar \(2012\)](#) é apresentado um ensaio da identificação e classificação de conjuntos de frutas se utilizado de redes neurais e combinações de características extraídas de imagens digitais. Nesse artigo são apresentadas as acurácia das redes neurais treinadas com características de cores e texturas, individualmente e ambas juntas, e apresenta em seus resultados que, para as frutas e características em questão, a

combinação de descritores de cores e texturas ofereceu melhores acurácia quando comparada ao uso de somente um tipo de característica.

[Patil et al. \(2011\)](#), que aborda a identificação e classificação de grãos se utilizando de características de cores e texturas, incluindo algumas das apresentadas em [Haralick et al. \(1973\)](#), diferentes espaços de cores também são testados, apresentando, para o *paper* em questão, variabilidade quanto às acurácia dos testes, tendo sido o melhor obtido no espaço de cores CIELAB.

Em [Majumdar et al. \(1996\)](#) a classificação de grãos, a partir de propriedades ópticas, é apresentada. O trabalho se utilizou de um espectrocolorímetro para a medição da reflectância nos objetos avaliados e, adicionalmente, também aborda e trabalha com diferentes espaços de cores, apontando, inclusive, algumas semelhanças, relações e diferenças entre os mesmos.

[Al-Marakeby et al. \(2013\)](#) aborda a inspeção da qualidade de alimentos, sendo maçãs, tomates, ovos e limões, avaliados, de forma rápida, para a aplicação prática dos resultados. O trabalho apresenta a proposta de um sistema de visão computacional para as classificações dos produtos citados e utiliza técnicas de segmentação de imagem, conversão de cores, redimensionamento, *thresholding* de cores e análises de histogramas. Além disso, o estudo também informa que um banco de imagens de 1000 itens, 250 figuras de cada classe, foi utilizado no mesmo.

O artigo publicado em [Haidar et al. \(2012\)](#) aborda sobre a classificação, baseada em imagens, de tâmaras. A pesquisa apresenta a combinação de diversas características extraídas das imagens e diversas técnicas de classificação. Os descritores apresentados são referidos como pertencentes aos grupos de características relacionadas a cor, tamanho e forma, ou textura e, além disso, também utilizada de técnicas como detecção de borda, análise de histograma, redes neurais e *thresholding* adaptativo. A classificação por redes neurais, se utilizando da combinação das características apresentadas, ofereceu a melhor acurácia na pesquisa, atingindo a precisão de 98,6% na classificação.

[Olunloyo et al. \(2012\)](#) apresentada um protótipo de um nariz eletrônico para a avaliação da qualidade de amêndoas de cacau. Utilizou-se de redes neurais e de amêndoas da prova de corte, comparando os resultados obtidos com os dos especialistas que fizeram os testes. A proposta atingiu 95% de acurácia em seus testes.

O uso de redes neurais, técnicas de visão computacional e visão de máquina para a avaliação da qualidade de um tipo de laranja são apresentados em [Kondo et al. \(2000\)](#). A pesquisa apresentou o uso de características descrevendo a cor, forma, e superfície das frutas como formas não-destrutivas de inferir sobre a quantidade de açúcar e ácido das laranjas. Imagens de trinta frutas foram utilizadas para o testes e, durante a conclusão, os autores apresentam a necessidade de mais imagens para a maior acurácia nas análises,

que em sua maioria não ofereceu resultados conclusivos.

[Khotanzad e Lu \(1990\)](#) apresenta o uso de redes neurais para a classificação de imagens de letras morfologicamente alteradas por rotação, translação, escala e ruído. Uma rede perceptron multicamada é utilizada e treinada com características diferentes, como os momentos de Zernik ([ZERNIKE; MIDWINTER, 2006](#)).

É apresentado em [Zhang et al. \(2016\)](#) a classificação de frutas se utilizando de redes neurais artificiais, onde trabalhou-se com um dataset contendo 1653 imagens de 18 classes diferentes, utilizou diversas técnicas de processamento de imagens, como extração de descritores de características de cores, texturas e formas e também otimizações baseadas em biogeografia. A maior acurácia obtida foi de 89,11%.

A classificação de tomates utilizando redes neurais é apresentado em [Louro et al. \(2006\)](#). Na pesquisa em questão, cento e dois tomates foram divididos em quatro classes, de acordo com suas colorações e tamanho, com as imagens digitais dos mesmos sendo registradas através de um protótipo. É interessante observar que, no estudo em questão, foi-se efetuada a troca do material do plano de fundo do protótipo para a melhor segmentação das imagens resultantes e, além disso, os autores sugerem, como trabalhos futuros, a realização da classificação em outro espaço de cor, o CIELAB. As imagens originais foram trabalhadas no espaço de cor RGB.

A detecção e classificação de defeitos em frutas é pesquisada em [Pencue e León-Téllez \(2003\)](#), onde um conjunto de imagens digitais de 165 frutas são divididos em cinco classes, são extraídas descritores de características das imagens e é treinada, por retro-propagação, uma rede neural artificial perceptron multicamada. A utilização de dois espaços de cores é abordada, o RGB e o HSI e, além disso, apresenta resultados com acurácia de 92,5%.

A classificação de café-cereja é apresentando em [Sandoval e Prieto \(2009\)](#), onde nove características, de cor, forma e textura, de 2400 imagens, sendo divididas em oito classes, segundo fases de maturação do café, e foi-se utilizado o classificador Bayesiano como técnica de classificação. A acurácia obtida foi de 96,88%.

[Shahin et al. \(2002\)](#) aborda sobre a classificação de maçãs, baseado em defeitos de superfície, se utilizando de redes neurais. Treinaram-se várias redes neurais, por algoritmo de retro-propagação, variando os parâmetros e configurações das redes. Então, depois do treinamento de todas as redes, foi selecionada a que ofereceu maior acurácia e a utilizou para testes seguintes. É interessante notar que o estudo se refere à arquitetura de rede utilizada como "arquitetura de rede de retro-propagação de três camadas", em tradução livre.

A avaliação de manchas na pele, se utilizando de processamento de imagens, é apresentada em [Adonias e Regis \(2015\)](#), onde são testados o método de Canny, Otsu

e Watershed para a identificação e segmentação da região de interesse. Além disso, a pesquisa também utilizou da média de cores da região de interesse e dos descritores de textura de Haralick.

Já em [Ramos \(2003\)](#), a classificação de frutos, se utilizando de redes neurais artificiais, do tipo perceptron multicamadas, treinadas por algoritmo de retro-propagação, é trabalhada. Diversas topologias de redes são testes e, após os testes, foi selecionada a que proveu melhor resultado. Resultando, para as quatro classes de classificação, tendo como parâmetros o peso e o diâmetro dos frutos, mapeados em um vetor, a acurácia de 99,22%.

[Kılıç et al. \(2007\)](#) apresenta um sistema de classificação de sementes utilizando descritores de tamanho e cor para e redes neurais. A arquitetura utilizada foi uma rede feedforward, o dataset de imagens contém 511 sementes e o espaço de cores utilizado para a extração das características foi o RGB. O sistema apresentado possui uma parte física, que é um protótipo para a captura de imagens padronizadas, e, além disso, a acurácia geral obtida nos testes foi de 90,6%.

Um sistema de visão computacional para a classificação de sementes de café é apresentado em [Oliveira et al. \(2016\)](#). Os espaços de cores RGB e CIELAB são utilizando durante a pesquisa, com a conversão do primeiro para o segundo para a extração de características a serem utilizadas. As imagens utilizadas no modelo foram obtidas de forma padronizada em um ambiente controlado, e também se é discutido um modelo para a transformação dos espaços de cores em questão. Além disso, uma rede neural perceptron multicamada, treinada utilizando o algoritmo de Levenberg-Marquardt, bem como se teve o uso de um classificador Bayesiano. A acurácia de 100%, é apresentado como resultado da pesquisa, acertando todas as classificações.

[OYAMA et al. \(2013\)](#) apresenta um estudo sobre a classificação de sementes de café se utilizando descritores de cor, forma e textura. Uma rede neural perceptron multicamada, treinada por algoritmo de retro-propagação, foi utilizada no sistema. Também são abordadas as diferenças e peculiaridades entre os diferentes espaços de cores, incluindo RGB, CIELAB, HSV, além de outros. Por fim, conclui-se que os descritores de texturas proveram maior poder de discriminação dentre os descritores testados, atingindo uma acurácia de 80,98%.

A classificação automática de leguminosas utilizando-se dos filamentos das folhas é apresentado em [Larese et al. \(2014\)](#). O *paper* apresenta as técnicas de máquina de vetor de suporte, análise de discriminante e florestas aleatórias como métodos de classificação. Descritores de forma, tamanho, cor e textura não são utilizados por se tratar da classificação de espécies cujas informações acima são similares mas, ainda assim, reconhece que estas são características válidas, só não são úteis neste estudo. O trabalho atingiu 92,0% de precisão na classificação de grãos de soja.

[Verma \(2010\)](#) aborda sobre a classificação de grãos de arroz se utilizando de uma rede neural perceptron multicamada, treinada com algoritmo de retro-propagação. Diversas técnicas de processamento de imagens foram utilizadas, como a binarização e o método de *watershed*, que contribuiu especialmente para os casos em que existiam grãos sobrepostos ou aglutinados. A acurácia do sistema proposto é retratada com mais de 90,0%.

Uma pesquisa preliminar a esta dissertação está presente em [Santos et al. \(2018\)](#), onde foram-se efetuados testes enquanto a base de imagens ainda não estava completa, para a criação do modelo presente nesta dissertação. No trabalho em questão uma rede neural perceptron multicamada, com taxa de aprendizagem de 10^{-1} , número máximo de épocas de 10^3 , erro máximo desejado de 10^{-5} , calculado através do erro quadrático médio, e treinamento com algoritmo de retro-propagação, foi treinada com diversas combinações de características estruturais, de cores e de texturas. A melhor acurácia foi atingida com a utilização das médias das camadas de cores RGB, média da cor da imagem em tons de cinza, e a área da amêndoaa para o treinamento da rede, resultando em 99,73% de acurácia. Tal *paper* foi feito quando a base de imagens possuía onze classes completas.

Outro trabalho que antecede a esta dissertação se encontra em [Santos e Palmeira \(2018\)](#), onde uma versão prévia da base de imagens foi utilizada com o intuito da modelagem de números fuzzy. O *paper* em questão testa diferentes números fuzzy construídos sob diversas perspectivas para a modelagem das cores das classes de amêndoas porém, tendo em vista a abordagem embrionária desta pesquisa, foi-se decidido aplicar as metodologias presente nesta dissertação antes de utilizar a teoria fuzzy para a modelagem de uma solução para o problema.

3 Fundamentação Teórica

3.1 Prova de Corte

A prova de corte, teste de corte ou *cut test*, é um teste de qualidade efetuado em amêndoas de cacau para analisar suas características internas e classificá-las de acordo com uma normativa.. Este teste é de extrema importância pois, além de classificar a qualidade da amostra, possibilitar a inferência do processo de fermentação e estado no fruto no momento da colheita, possibilitando assim a melhora em processos futuros. Também é nele que são detectadas substâncias nocivas à saúde humana, caracterizadas como:

Substâncias nocivas à saúde: substâncias ou agentes estranhos de origem biológica, química ou física, que sejam nocivos à saúde, tais como: as micotoxinas, os resíduos de produtos fitossanitários ou outros contaminantes, previstos em legislação específica vigente, não sendo assim considerados aqueles cujo valor se verifica dentro dos limites máximos previstos ([AGRICULTURA, 2008](#), p.2).

Modelos de tábuas utilizadas para a prova de corte são apresentados na Figura 1. Tais tábuas possuem três subdivisões, cada uma com espaço para 100 amêndoas, totalizando a avaliação de trezentas amêndoas.

Figura 1 – Tábuas utilizadas para a prova de corte, sendo a da esquerda uma vazia e a da direita uma tábua preenchida com amêndoas já cortadas



Fonte: Autoria própria

As amêndoas, como exibido na Figura 2, são cortadas longitudinalmente e

organizadas nas tábuas de corte, para que especialistas analisem os seus interiores e infiram sobre as suas cores, compartimentações e defeitos.

Figura 2 – Aproximação em amêndoas sendo analisadas na tábua da prova de corte



Fonte: Autoria própria

Além das análises internas das amêndoas, como apresentado na Tabela 1, onde exibem-se as tolerâncias de defeitos para a classificação de cacau em tipos de qualidade, também se analisam outras propriedades das amêndoas, como danos causados por insetos e presença de fumaça.

Tabela 1 – Tolerância de defeitos dos tipos de lotes de amêndoas de cacau

Enquadramento do Produto	Defeitos					
	Mofadas	Fumaça	Danificadas por insetos	Ardósia	Germinadas	Achatadas
Tipo 1	De zero até 4,0%	De zero até 1,0%	De zero até 4,0%	De zero até 5,0%	De zero até 5%	De zero até 5,0%
Tipo 2	Acima de 4,0% até 6,0%	Acima de 1,0% até 4,0%	Acima de 4,0% até 6,0%	Acima de 5,0% até 10,0%	Acima de 5,0% até 6,0%	Acima de 5,0% até 6,0%
Tipo 3	Acima de 6,0% até 12,0%	Acima de 4,0% até 6,0%	Acima de 6,0% até 8,0%	Acima de 10,0% até 15,0%	Acima de 6,0% até 7,0%	Acima de 6,0% até 7,0%
Fora de Tipo	Acima de 12,0% até 25,0%	Acima de 6,0%	Acima de 8,0%	Acima de 15,0%	Acima de 7,0%	Acima de 7,0%

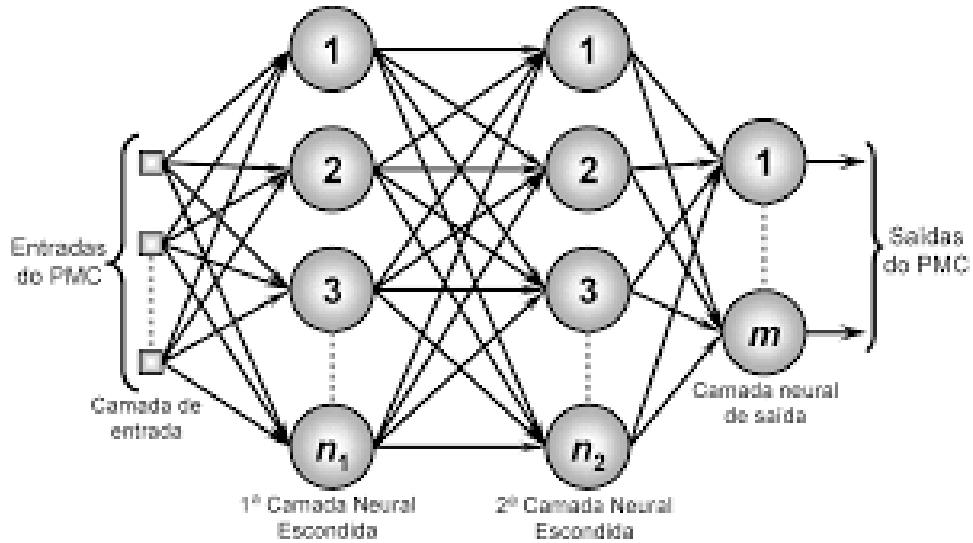
Fonte: [Agricultura \(2008\)](#)

3.2 Redes Neurais

As redes neurais artificiais (RNA) são modelos computacionais inspirados no funcionamento do sistema nervoso central de animais, onde os neurônios formam conexões e, a partir disso, as memórias e conhecimentos se relacionam. Ainda sobre as redes neurais, existem diversos tipos e com diversas configurações possíveis, de modo que um tipo de rede neural pode fornecer melhor resultado que outros para um certo problema e, além disso, RNA de um mesmo tipo, com configurações diferentes, podem fornecer resultados significativamente discrepantes entre si. As RNA podem ser aplicadas em diversas áreas, como observado nos trabalhos explorados no Capítulo 2 ([AMBRÓSIO, 2002; MATICH, 2001; OLABE, 1998](#)).

O tipo de RNA Perceptron Multicamada (PMC), treinada de modo supervisionado com algoritmo de retro-propagação, foi utilizado para os testes e modelos apresentados nesta dissertação, visto as suas variadas aplicações, inclusive para a classificação de imagens, e com resultados interessantes apresentados em outros trabalhos na literatura. Uma rede PMC é caracterizada pela presença de ao menos uma camada de neurônios intermediárias, ou escondida, entre as camadas de entrada e de saída. Podemos observar um exemplo de uma rede PMC na Figura 3 ([GLINGANI; AMBRÓSIO, 2009](#)).

Figura 3 – Exemplo de rede PMC



Fonte: [SILVA et al. \(2010\)](#)

Diversas configurações devem ser definidas para a criação de uma rede PMC, como: taxa de aprendizagem, número máximo de épocas, máximo erro desejado, número de camadas escondidas e número de neurônio nas camadas escondidas. A taxa de aprendizagem, comumente apresentada pela letra grega eta (η), interfere na velocidade de convergência e na taxa de aprendizagem da rede neural. O valor desta configuração influencia as mudanças nos pesos sinápticos da rede e, por este motivo, se um valor muito baixo for escolhido, dependendo da inicialização da rede e do problema de classificação, pode acontecer de a RNA, durante o seu treinamento, cair em um problema de mínimo local nas medições dos erros para a atualização dos pesos sinápticos, como ilustrado na Figura 4 ([SILVA et al., 2010](#); [SANCHEZ, 2009](#)).

Figura 4 – Ilustração do problema do mínimo local causado por uma taxa de aprendizado muito baixa



Fonte: [Sanchez \(2009\)](#)

Em contrapartida, uma taxa de aprendizagem muito alta, mesmo fazendo com que a convergência da rede seja mais rápida e amenizando o problema do mínimo local, pode fazer com que se caia em um problema de oscilação do erro no entorno do mínimo global, como mostrado na Figura 5.

Figura 5 – Ilustração do problema do oscilação causado por uma taxa de aprendizado muito alta



Fonte: [Sanchez \(2009\)](#)

Observando-se os potenciais problemas advindos de uma escolha inadequada no valor da taxa de aprendizagem, é interessante que se encontre um valor que não seja

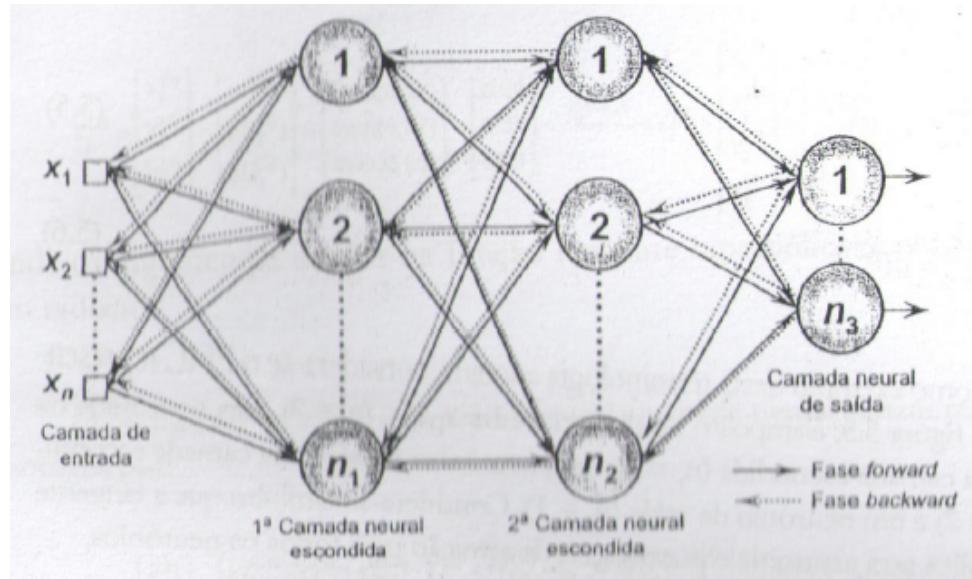
pequeno a ponto de causar problema no mínimo local e nem grande a ponto de causas o problema de oscilação no mínimo global. Já com relação ao valor de (η) a ser escolhido, existem diversas sugestões na literatura como, por exemplo: a escolha de uma taxa inicial alta, fazendo com que a mesma decresça progressivamente durante o treinamento da rede, se caracterizando uma taxa de aprendizagem adaptativa; testes empíricos de valores e suas respectivas redes configuradas; ou valores específicos sugeridos como interessantes para o treinamento da rede (SILVA et al., 2010).

O número máximo de épocas é uma condição para se encerrar o treinamento da RNA, evitando-se assim potenciais laços permanentes, como o apresentado na oscilação em torno do mínimo global, e também pode ser utilizado para limitar o tempo de treinamento. Já o máximo erro desejado, que também é uma condição de parada do treinamento da rede, fará com que o treinamento da rede se encerre caso a quantidade de erro presente na rede seja "aceitável" (BARRETO, 2002; SILVA et al., 2010).

Existem também outros elementos que compõe as redes neurais, como os pesos sinápticos, comumente descritos por díblio minúsculo (w), ou ômega (ω), que são valores que influenciam o limiar de ativação ao atribuírem pesos para os sinais dos valores de entrada e de neurônios. Outro elemento presente nas RNA é o limiar de ativação, comumente descrito por teta (θ), que é uma espécie de "gatilho de memória" que faz com que o neurônio se ative se o limitar foi atingido pelos pesos sinápticos (SILVA et al., 2010; SANCHEZ, 2009; AMBRÓSIO, 2002).

Quanto ao treinamento da rede, ele é feito em duas etapas, como ilustrado na Figura 6, sendo uma delas descrita como *forward*, em que as entradas da rede (descritas na imagem como x_1, x_2 até x_n) são processadas por todas as camadas até gerarem resultados na saída, e outra *backward*, em que as respostas obtidas são comparadas com as desejadas e utilizados para ajustar os pesos sinápticos e limiares de ativações dos neurônios.

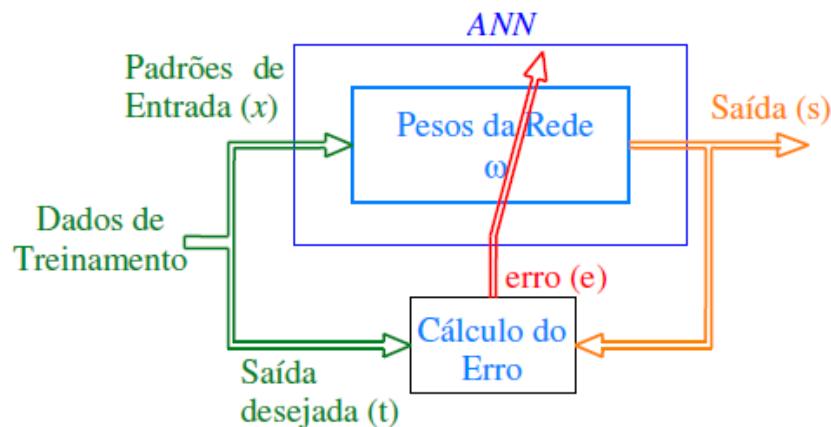
Figura 6 – Etapas de treinamento de uma rede PMC



Fonte: SILVA et al. (2010)

A Figura 7 também ilustra o processo de treinamento de uma rede PMC. Nela é possível observar com mais facilidade o fluxo de informações retratados na Figura 6.

Figura 7 – Ilustração do processo de treinamento de uma PMC



Fonte: Sanchez (2009)

Um exemplo ilustrando detalhadamente o treinamento de uma PMC pode ser encontrado em SILVA et al. (2010), na Seção 5.3.

3.3 Descritores de Características de Imagens

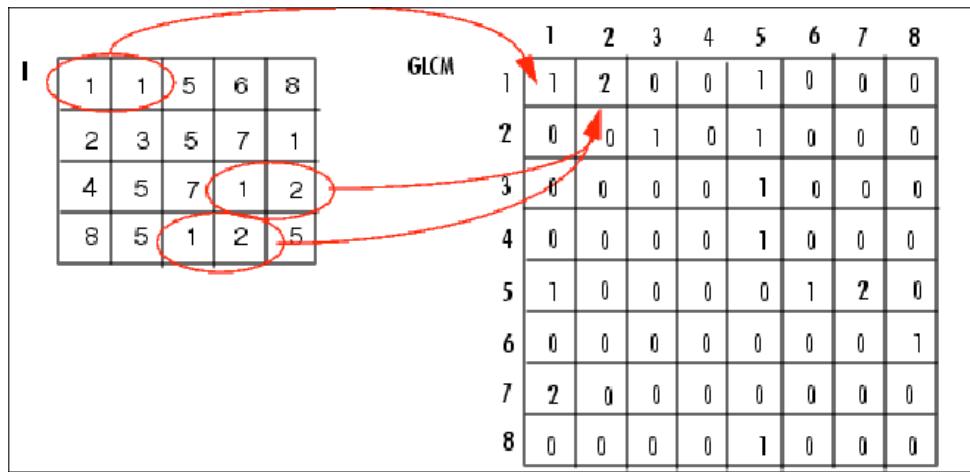
Descritores de características de imagens são descritores que carregam informações referentes à imagem e é possível saber através destes descritores, por exemplo, se a imagem é composta por intensidades de cores mais altas ou mais baixas, revelando assim se a imagem é mais clara ou escura; também é possível extraír a homogeneidade da imagem, por exemplo, podendo inferir através deste descritor se a imagem é mais ou menos homogênea em relação à sua cor ([HARALICK et al., 1973](#)).

3.3.1 Descritores de Texturas de Haralick

Os descritores de textura de Haralick são um conjunto de características de uma imagem que podem ser utilizados em modelos de classificação. Estes descritores texturais são extraídos de uma matriz de co-ocorrência (Gray-Level Co-Occurrence Matrix, ou GLCM) de uma imagem em tons de cinza, construída ao se analisar os tons dos pixeis de suas distribuições e disposições na imagem ([HARALICK et al., 1973](#)).

A matriz de co-ocorrência é uma matriz quadrada com dimensões iguais à resolução de contraste da imagem sobre qual a mesma está sendo construída. Ela armazena a ocorrência dos tons, em uma direção específica, na posição condizente às suas resoluções, isto é: podemos observar na Figura 8 a construção de uma GLCM a partir de uma imagem I, já exibida em forma de matriz; a imagem contém resolução de contraste oito, possui oito tons de cinza diferentes, o que resulta em que a matriz de co-ocorrência tenha dimensões 8x8. A GLCM em questão está sendo construída ao se avaliar a imagem em 45°, que é basicamente observar o elemento atual e seu próximo vizinho à direita, e, para cada par, soma-se na matriz de co-ocorrência, na posição (T,U), onde T é o valor do elemento atual e U é o valor do elemento à direita, o valor de um. Desta forma, como descrito na Figura 8, a posição (1,1) da GLCM armazena a quantidade de vezes em que a tonalidade 1 apareceu duas vezes seguidas na imagem e, da mesma forma, (1,2) armazenará a quantidade de vezes que a tonalidade 1 foi seguida da tonalidade 2 na imagem ([HAIDAR et al., 2012](#); [HARALICK et al., 1973](#); [AGUIAR et al., 2016](#)).

Figura 8 – Construção de uma matriz de co-ocorrência de uma imagem com resolução de contraste de oito tons



Fonte: [MATLAB... \(2018\)](#)

[Haralick et al. \(1973\)](#) considera que tonalidades e textura das imagens tem uma ligação inseparável, mesmo com um dominando o outro em alguns casos. Adicionalmente, Haralick sugere o uso de 28 características texturais, sendo elas as médias e variâncias das aplicações das fórmulas descritas na Tabela 2 em quatro GLCM construídas em ângulos diferentes.

As fórmulas para o cálculo dos descritores de textura de Haralick estão dispostas na Tabela 2 e nas Equações 1, 2, 3 e 4, assim como dispostas no artigo original, retratado em [Haralick et al. \(1973\)](#), em que:

1. $p(i, j)$ significa pixel na posição i, j na matriz de co-ocorrência;
2. N_g número de tons de cinza distintos na imagem;
3. $p_x(i)$ e $p_y(i)$ são as i -ésimas posições nas matrizes de distribuição de probabilidade conjunta criada a partir das matriz de co-ocorrência;
4. μ_x e μ_y são os desvios médios de p_x e p_y ;
5. σ_x e σ_y são os desvios pedrões de p_x e p_y ;
6. Equações 1, 2, 3 e 4 apresentam, respectivamente, como H_{XY} , H_{XY1} , H_{XY2} e Q são calculados;
7. H_X e H_Y são as entropias de p_x e p_y , respectivamente, e são calculadas seguindo a formulação apresentada na Tabela 2.

$$HXY = - \sum_i \sum_j p(i,j) \log\{p(i,j)\} \quad (1)$$

$$HXY1 = - \sum_i \sum_j p(i,j) \log\{p_x(i)p_y(j)\} \quad (2)$$

$$HXY2 = - \sum_i \sum_j p_x(i)p_y(j) \log\{p_x(i)p_y(j)\} \quad (3)$$

$$Q(i,j) = \sum_k \frac{p(i,k)p(j,k)}{p_x(i)p_y(k)} \quad (4)$$

As características apresentadas na Tabela 2 representam aspectos da imagem cuja matriz de co-ocorrência foi produzida, com o Segundo Momento Angular (f1) sendo uma medida da homogeneidade de tons na imagem, o Contraste (f2) sendo uma medição do contraste da figura e a Correlação (f3) representando a medida da dependência linear dos tons de cinza, por exemplo ([HARALICK et al., 1973](#)).

Tabela 2 – Equações para o cálculo dos descritores de textura de Haralick

Característica	Equação
Segundo Momento Angular (f1)	$\sum_i \sum_j \{p(i, j)\}^2$
Contraste (f2)	$\sum_{n=0}^{N_g-1} n^2 \left(\sum_{\substack{i=1 \\ i-j =n}}^{N_g} \sum_{j=1}^{N_g} p(i, j) \right)$
Correlação (f3)	$\frac{\sum_i \sum_j (i, j)p(i, j) - \mu_x \mu_y}{\sigma_x \sigma_y}$
Variância (f4)	$\sum_i \sum_j (i - \mu)^2 p(i, j)$
Momento Inverso da diferença (f5)	$\sum_i \sum_j \frac{1}{1 + (i - j)^2} p(i, j)$
Soma das Médias (f6)	$\sum_{i=2}^{2N_g} ip_{x+y}(i)$
Soma das Entropias (f7)	$\sum_{i=2}^{2N_g} p_{x+y}(i) \log\{p_{x+y}(i)\}$
Soma das Variâncias (f8)	$\sum_{i=2}^{2N_g} (i - f7)^2 p_{x+y}(i)$
Entropia (f9)	$-\sum_i \sum_j p(i, j) \log\{p(i, j)\}$
Variância da Diferença (f10)	variância de p_{x-y}
Entropia da Diferença (f11)	$\sum_{i=0}^{N_g-1} p_{x+y}(i) \log\{p_{x+y}(i)\}$
Medias de Informações de Correlação (f12) ¹	$\frac{HXY - HXY1}{\max\{HX, HY\}}$
Medias de Informações de Correlação (f13) ¹	$(1 - \exp[-2.0(HXY2 - HXY)])^{\frac{1}{2}}$
Coeficiente Máximo de Correlação (f14) ¹	$(\text{Segundo maior autovalor de } Q)^{\frac{1}{2}}$

Fonte: [Haralick et al. \(1973\)](#)

3.3.2 Descritores de Estrutura

Descritores de características relacionados à estrutura dos elementos a serem utilizados para o treinamento de uma rede neural também estão presentes na literatura e, em alguns casos, os modelos treinados com os descritores em questão são melhores dos que os treinados sem ([NANDI et al., 2014](#); [HAIDAR et al., 2012](#)).

Existem diversos descritores de estrutura, também referidos como formas, das imagens e, para este modelo, os descritores de área e perímetro, cujos métodos de obtenção são apresentados na Seção 4.3, foram utilizados. Ambos foram escolhidos por fazerem parte do conjunto de características para classificações de imagens em outros trabalhos e, além disso, pela observação da variabilidade na área e no perímetro das imagens aqui classificadas, como as diferenças nos perímetros entre imagens de amêndoas Aglutinadas e de amêndoas achatadas, como observado na Figura 9 ([NANDI et al., 2014](#); [HAIDAR et al., 2012](#)).

Figura 9 – Diferenças visíveis entre as classes de uma amêndoas, na esquerda, uma amêndoas achatada, na direita



Fonte: Autoria própria

3.3.3 Descritores de Cores

As cores das amêndoas são vitalmente importantes para a classificação do modelo e influenciam diretamente nas classes da prova de corte, como explorado na Seção 3.1. Desta forma, é racional a busca por um conjunto de características que possam representar ou auxiliar na representação da coloração das amêndoas para o treinamento da rede neural ([PATIL et al., 2011](#); [NANDI et al., 2014](#)).

A importância das cores no processo de classificação das amêndoas na prova corte, aliada à grande ajuda e melhoria que tais descritores proveem na identificação e classificação em diversos modelos, amplamente presentes na literatura, inclusive para cereais, grãos, sementes e frutas, oferecem alicerces teóricos para o uso de tais descritores no modelo aqui proposto ([PENCUE; LEÓN-TÉLLEZ, 2003](#); [PATIL et al., 2011](#); [SAVAKAR, 2012](#); [HAIDAR et al., 2012](#); [LOURO et al., 2006](#); [SANDOVAL; PRIETO, 2009](#)).

Quatro características de cores foram selecionadas para o teste, visto os bons

resultados observados em outros modelos de classificações em que as mesmas estavam presentes, são elas: as médias de cores de cada uma das camadas RGB, isto é: média das camadas de cores azul, vermelha e verde; e a média da camada em tons de cinza. A ilustração e explanação dos processamentos efetuados nas imagens antes da extração de tais características podem ser observados na Seção 4.2.1. Somente os pixels das amêndoas são utilizados para os cálculos das médias (HAIDAR et al., 2012; LOURO et al., 2006; SANDOVAL; PRIETO, 2009).

A Equação 5 exibe a fórmula para o cálculo da média para a camada vermelha, considerando-se uma imagem I, em RGB, de dimensões 3240x4320, em que:

1. $p_{s4R}(i, j)$ significa o pixel na posição (i,j) na camada vermelha extraída da imagem no passo quatro de processamento da Seção 4.2.1;
2. $p_{s5}(i, j)$ significa o pixel na posição (i,j) na imagem em tons de cinza do quinto passo, também presentes na Seção 4.2.1;
3. (*Área*) é a área da amêndoa que está em processamento;
4. *Média – vermelha* é a média de cor da camada vermelha, como apresentada na Figura 24.

$$\text{Média - vermelha} = \frac{\sum_{\substack{i=1 \\ j=1}}^{j=4320 \\ i=3240} p_{s4R}(i, j)}{p_{s5}(i, j) \neq 0} \quad (5)$$

Suplementarmente, para as médias das camadas azul e verde foi-se utilizada a mesma metodologia descrita para a camada vermelha.

4 Materiais e Métodos

4.1 Base de Imagens de Amêndoas de Cacau Classificadas na Prova de Corte

Uma base de imagens, ou *dataset*, composta por imagens classificadas na prova de corte foi construída para a criação deste modelo. Tal *dataset* foi implementado devido a não ter sido encontrada uma base de imagens na literatura que possibilitasse a criação do modelo presente nesta dissertação.

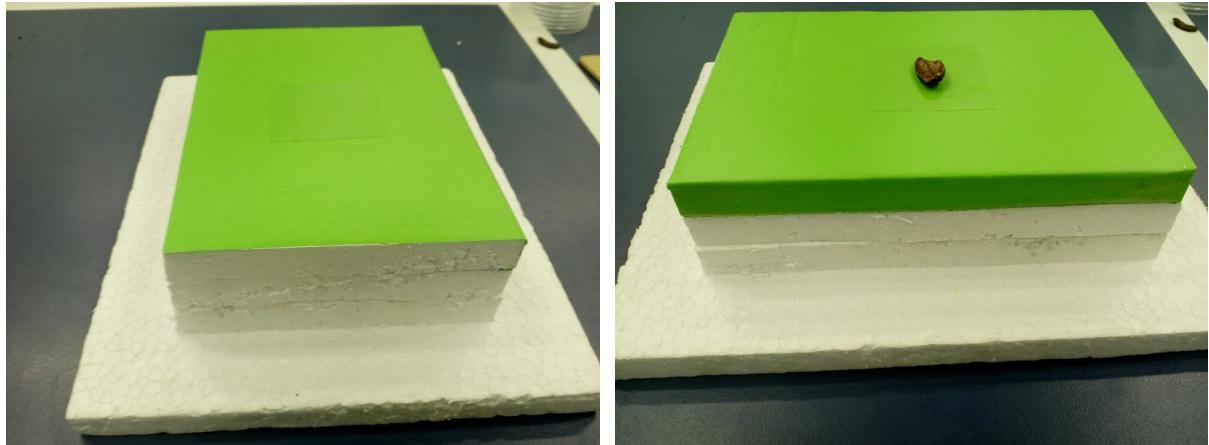
O protótipo desenvolvido para a captura das imagens será explorado na Seção 4.1.1, as configurações da câmera digital utilizada no processo, bem como o método de registro de imagens, serão apresentadas na Seção 4.1.2.

4.1.1 Protótipo para Captura

Uma câmara fotográfica foi construída para normalizar as condições de ambiente e distância da câmera até as amêndoas. O protótipo em questão foi construído com isopor e suas medidas foram obtidas através de várias tentativas anteriores. A câmara é constituída por duas partes: uma em que a semente e o plano de fundo estão dispostos, que chamaremos de Base, e outra em que a câmera e as lâmpadas são posicionadas, que chamaremos de Topo.

O material e a cor em que o plano de fundo, ou background, exibido na Figura 10, foi construído com papel adesivo *contact* verde, devido a sua capacidade de limpeza, visto que algumas sementes liberam poeira, e devido à sua coloração quase homogênea, o que influenciará para facilitar na extração do plano de fundo das imagens.

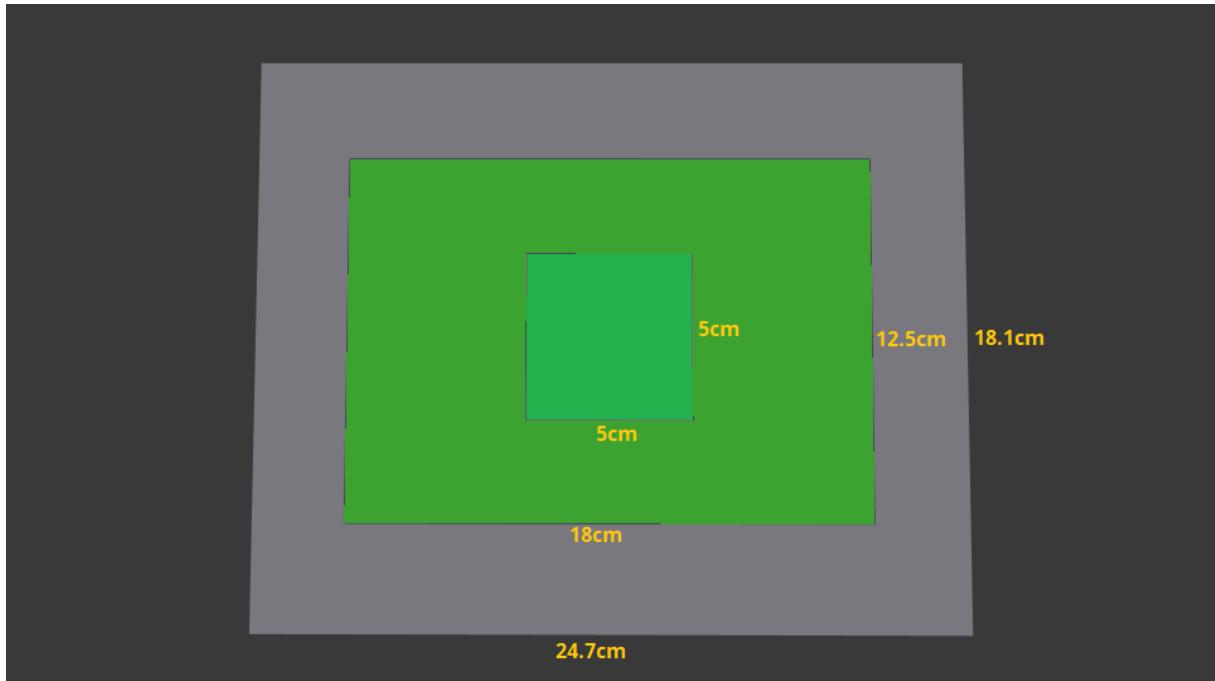
Figura 10 – A Base do protótipo para a captura das imagens para a construção do *dataset*



Fonte: Autoria própria

No centro da Base existe um quadrado, também feito do mesmo material que o plano de fundo, com proporção quadrada de cinco centímetros (cm) por cinco centímetros (5cmx5cm), também exibido na Figura 10, que foi criado para auxiliar no melhor posicionamento das amêndoas para a captura das imagens. A estrutura da Base é composta por quatro peças de placas de isopor, todas com 1,5 cm de diâmetro, e coladas com cola específica para o material. As dimensões destas placas são: 24,7cm x 19,8cm para o pedaço maior, que dá suporte para todo o protótipo, e 18cm x 12,5cm para cada um dos três pedaços do centro, que servem para posicionar as amêndoas na altura desejada. Uma melhor visualização destas medidas podem ser observadas na Figura 11, onde um modelo bidimensional da Base apresentada na Figura 10, é disposto. Todo o material utilizado no plano de fundo foi da mesma cor, o quadrado central é exibido em cor diferente na Figura 11 com a intenção de facilitar a visibilidade das medidas.

Figura 11 – Modelo bidimensional com as medidas da Base do protótipo de captura



Fonte: Autoria própria

O Topo foi criado utilizando placas de isopor de 3cm de espessura para os lados e duas placas de 1,5cm de espessura para a parte de posicionamento da câmera, onde uma delas foi cortada para posicionar a câmera de forma imóvel. Além disso, uma abertura de 5cm de diâmetro foi feita para o posicionamento da lente da câmera. A Figura 12 apresenta as medidas e cortes previamente explanados, ambos com as luzes internas acendidas.

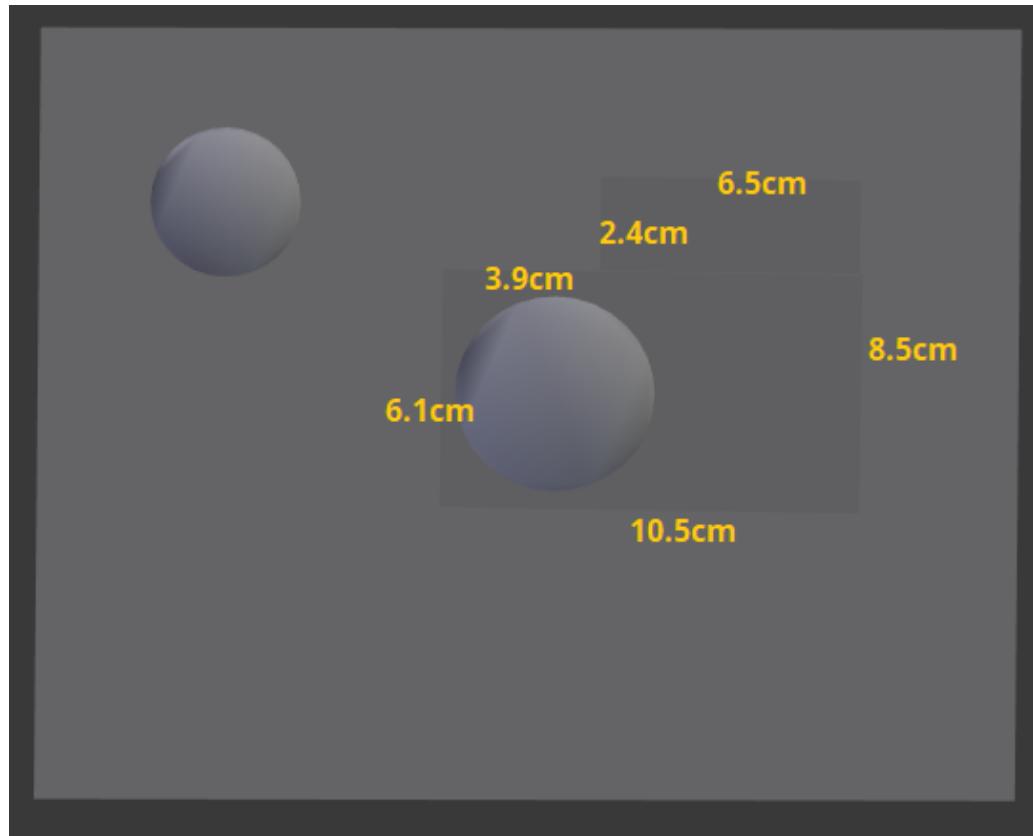
Figura 12 – Topo do protótipo de captura, onde: na esquerda observamos, com a câmera posicionada e as luzes acesas, e na direita sem a câmera, uma amêndoia sendo registrada



Fonte: Autoria própria

As dimensões do Topo da caixa são 19,7cm x 24,6cm para a parte onde a câmera é posicionada, 13,1cm x 24,8cm para os dois lados maiores, onde não possuem lâmpadas, e 13cm x 12,9cm para os dois lados menores, onde existem duas lâmpadas posicionadas. Em adição, pode-se observar melhor as dimensões de onde a câmera é posicionada na Figura 13, que consiste em um modelo bidimensional da parte superior do Topo do protótipo.

Figura 13 – Modelo bidimensional com as medidas do local de posicionamento da câmera



Fonte: Autoria própria

Adicionalmente, três lâmpadas mini-dicroicas de diodos emissores de luz (*Light Emitting Diode*, ou LED), são utilizadas para a iluminação interna. As lâmpadas em questão foram escolhidas devido a sua boa iluminação e a sua tecnologia de "luz fria", para prevenir danos por aquecimento ao protótipo. Os três LEDs são iguais, com foco de 120°, que é o ângulo de abertura da iluminação, para iluminar o mais uniformemente possível o plano de fundo, minimizando a ocorrência de sombras e penumbbras nas imagens. As especificações técnicas das lâmpadas podem ser observadas na Tabela 3 e o modelo utilizado é o presente na Figura 14. Todas as lâmpadas foram conectadas em um circuito em paralelo.

Tabela 3 – Especificações das lâmpadas utilizadas

Especificações técnicas	
Marca	Iluctron
Abertura Angle	120°
Potência	2W
Tensão	110V e 220V
Intensidade Luminosa	200lm

Fonte: <http://www.iluctron.com.br>

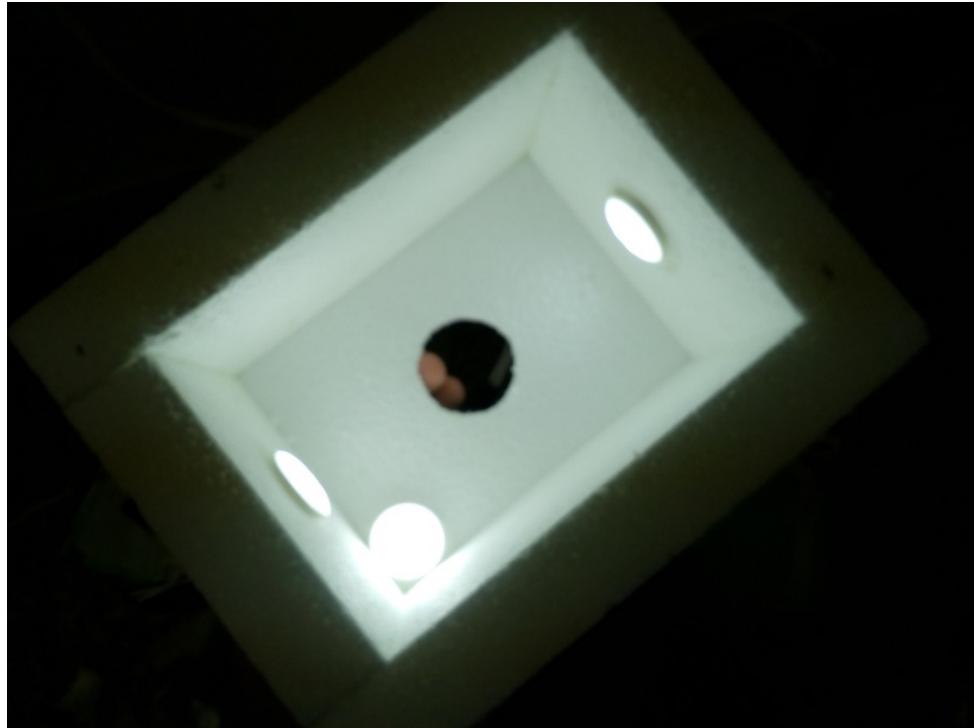
Figura 14 – Modelo das lâmpadas



Fonte: Adaptado de <http://www.iluctron.com.br>

Os posicionamentos das lâmpadas, como exibidos na Figura 15, são: exatamente no centro do lado to Topo, para as duas lâmpadas laterais, e no centro do quadrante superior direito, para a posicionada na parte onde a câmera fotográfica é posicionada. As lâmpadas foram posicionadas em uma abertura de 2,8cm de diâmetro e foram dispostas desta forma para minimizar o aparecimento de sombras dos lados das amêndoas e para iluminar o interior da mesma, para destacar a compartimentação interna.

Figura 15 – Posicionamentos das lâmpadas no interior do protótipo



Fonte: Autoria própria

4.1.2 Câmera e Configurações

Uma câmera fotográfica digital, com uma lente possuindo 25 milímetros de abertura, foi utilizada para a captura de todas as imagens. A máquina fotográfica foi configurada no modo "cena", com a opção de "fotos na neve" selecionada. Esta configuração foi escolhida devido à intensa iluminação interna, que ofuscava os outros modos da câmera. As configurações para captura foram: 14 mega-pixels de tamanho de imagem, sendo 4320x3240 pixels com proporção de 4:3; *flash* e detecção de faces desativadas, formato .JPG no espaço de cor RGB, com resolução de contraste de oito bits para cada camada de cor, totalizando 24 bits, e em modo de zoom de 2,5x constantes, que foi aplicado para melhor posicionar a amêndoia na imagem e desperdiçar menos espaço com o plano de fundo. Além disso, alguns segundos foram aguardados antes da captura de cada imagem, para a câmera focar na amêndoia. Uma foto da máquina utilizada é apresentada na Figura 16 e algumas de suas especificações são apresentadas na Tabela 4.

Figura 16 – Modelo de câmera digital utilizado para a construção do *dataset*

Fonte: Autoria própria

Tabela 4 – Algumas especificações da câmera utilizada

Especificações técnicas	
Zoom Óptico	10x
Zoom de Precisão Digital	20x (total)
Compatibilidade com Lente de Conversão F	Não
Distância de Focagem (F= MM)	3,5 - 5,5
Distância de Focagem (F=Conversão 35 MM)	4,25 - 42,5
Tipo CCD	25 - 250
Dimensões (Polegadas)	CCD Super HAD
Obturador Lento NR	Tipo 1/2,3 (7,76 mm)
Alerta de Oscilação	Sim
Controle de Exposição	Sim
	+/- 2,0 EV, incrementos de 1/3 EV

Fonte: <https://www.sony.pt>

4.1.3 Processo de Aquisição

As imagens registradas para o *dataset* foram retiradas de testes de corte em execução e foram previamente classificadas por um especialista do Centro de Inovação de Cacau (CIC). As amêndoas foram retiradas aleatoriamente de dezenas de testes efetuados ao longo de diversos meses. A captura da imagem foi feita logo após a classificação da imagem, que, para todas as situações, foi no máximo de cinquenta minutos depois que o corte da amêndoa foi efetuado. Este tempo máximo foi estabelecido se observando a média de tempo dos testes efetuados e pelo motivo de que as cores do interior de algumas amêndoas se alteram depois de um certo tempo de cortadas e expostas ao ambiente. A Figura 17 mostra o ambiente em que os testes de corte e a captura das imagens eram efetuados.

Figura 17 – À esquerda foi o ambiente em que os testes de corte foram efetuados e à direita foi o local onde as imagens foram registradas



Fonte: Autoria própria

4.2 Processamento de Imagens

As imagens do *dataset*, em sua forma original, estão com plano do fundo e podem possuir poeira, pedaços de outras sementes, isopor ou outros elementos que influenciam os resultados das características a serem extraídas para o modelo de classificação e, por este motivo, as imagens foram processadas para minimizar a interferência destes possíveis elementos na classificação.

Dois processos foram empregados para o processamento das imagens. O primeiro, descrito na Seção 4.2.1, foi o utilizado para tratar as imagens antes de extrair as características que foram utilizadas para este modelo porém, durante tal processamento, algumas imagens foram danificadas, como será explorado na Seção 5.1.2.1, e, com a intenção de minimizar estes danos e fornecer versões diferentes do *dataset* para a comunidade científica, um segundo método foi aplicado, que será explorado na Seção 4.2.2, com os resultados apresentados na Seção 5.1.2.2. As técnicas utilizadas para o processamento das imagens foram escolhidas a partir da observação de métodos de outros trabalhos de processamento de imagens na literatura (PENCUE; LEÓN-TÉLLEZ, 2003; PATIL et al., 2011; SAVAKAR, 2012; HAIDAR et al., 2012; LOURO et al., 2006; SANDOVAL; PRIETO, 2009; NANDI et al., 2014; MAJUMDAR et al., 1996).

4.2.1 Método A - Remoção de Não-Amêndoas

O primeiro método de processamento (ou Método A) consiste em seis etapas, que serão apresentadas nas seções a seguir. A ordem de execução das técnicas é vital para o processamento e, com a intenção de ilustrar melhor os efeitos de cada passo, as aplicações das técnicas na amêndoa Branca Chapada de número 34 serão descritas.

As imagens precisam ser processadas pois podem possuir poeira, pedaços de sementes de registros anteriores ou outros tipos de objetos não-amêndoas. Desta forma, o objetivo do método é a remoção do plano de fundo e dos objetos que não-amêndoas, preservando o máximo possível da semente de cacau.

4.2.1.1 Etapa 1 - Remoção do Plano de Fundo

A primeira etapa foi a utilização de técnicas de *thresholding* para a eliminação do plano de fundo, cujas imagens antes e depois do processo são apresentadas na Figura 18. O espaço de cores CIELAB foi utilizado durante este processamento, com a imagem sendo convertida para o espaço em questão antes do processamento e o resultado sendo convertido novamente para o espaço de cores RGB depois.

Figura 18 – À esquerda uma amêndoas Branca Chapada do *dataset* e na direita o resultado da aplicação do primeiro passo na imagem em questão



Fonte: Autoria própria

O CIELAB foi escolhido por ser utilizado com sucesso em outros trabalhos na literatura com objetivos similares a este e por causa dos grandes danos causados nas imagens ao se extrair o plano de fundo no espaço de cores RGB, como mostrados na Figura 19, em que, em uma tentativa foi utilizada um limiar de *thresholding* amplo, para preservar a semente, o que resultou na preservação de parte do plano de fundo, e na outra um muito restrito, que eliminou o plano de fundo mas danificou severamente a amêndoas (LOURO et al., 2006; OLIVEIRA et al., 2016; OYAMA et al., 2013).

Figura 19 – Duas tentativas de eliminar o plano de fundo no espaço de cores RPG, a da esquerda com o limiar muito amplo e a da direita com o limiar muito restrito



Fonte: Autoria própria

É importante notar também que, mesmo se utilizando o CIELAB, algumas sementes sofreram alguns danos, como serão explorados em 5.1.2.1, especialmente as das classes Branca Chapada, Branca Compartimentada e Mofada. Entretanto, o dano em questão não tirou das amêndoas as suas características de classes, como o mofo, de forma que as imagens depois do processo tem a mesma classificação das anteriores. É interessante destacar que a amêndoa utilizada na Figura 18 é da classe Branca Chapada e sofreu dos danos descritos aqui, mesmo sendo difícil observá-los na imagem.

4.2.1.2 Etapa 2 - Binarização da Imagem

O próximo passo no processamento, ou Etapa 2, foi a binarização do resultado obtido no passo anterior, de modo que todo pixel *não-background* se torne branco uniforme e todo pixel *background* continue preto uniforme, como mostrado na Figura 20. A técnica de *thresholding* por cor foi utilizada para tal efeito, e o objetivo desta parte é a criação de uma máscara de imagem para a remoção de possíveis poeiras ou outros elementos, que não sejam a amêndoa, de influenciarem nas características extraídas. Os limiares para o *thresholding* foram obtidos através de diversos testes efetuados com o software MATLAB e com a linguagem R.

Figura 20 – Na esquerda está o resultado da primeira técnica e na direita o resultado da aplicação da Etapa 2 em tal imagem



Fonte: Autoria própria

4.2.1.3 Etapa 3 - Remoção de Não-Amêndoas

A terceira etapa, ilustrada na Figura 21, consiste na segmentação da imagem em diversos corpos, cada um destes corpos sendo uma sub-região de pixels brancos conectados, em que somente o corpo de maior área, que é a própria amêndoa, é preservado. Este passo também é parte da criação da máscara que será aplicada na imagem original.

Figura 21 – Na esquerda está o resultado da imagem binarizada na Etapa 2 e na direita o resultado depois da Etapa 3



Fonte: Autoria própria

4.2.1.4 Etapa 4 - Aplicação de Máscara

Esta parte consiste na aplicação do resultado obtido na etapa três como máscara na imagem original, para preservar somente a amêndoа, como exibido na Figura 22. Somente a área que está em cor branca na máscara será preservada, todo o resto, em cor preta, será excluído.

Figura 22 – Na esquerda está o resultado da etapa três e na direita o resultado da aplicação dessa como máscara na imagem original, eliminando eventuais poeiras ou pedaços de outros corpos que não estão na amêndoа



Fonte: Autoria própria

4.2.1.5 Etapa 5 - Conversão para Tons de Cinza

Este passo, ilustrado na Figura 23, consiste na conversão da imagem obtida na Etapa 4 de RGB para tons de cinza. A execução desta técnica foi feita para possibilitar a criação de uma matriz de co-ocorrência e, em seguida, obter os descritores de texturas de Haralick. A função *rgb2gray*, do MATLAB, cuja fórmula é apresentada na Equação 6, foi utilizada para a conversão, em que R(i,j), G(i,j) e B(i,j) significam os valores do pixel (i,j) na camada R, G e B, respectivamente, e as constantes multiplicando cada valor são pesos dados a cada uma das camadas.

$$Cinza(i, j) = 0.2989 * R(i, j) + 0.5870 * G(i, j) + 0.1140 * B(i, j) \quad (6)$$

Figura 23 – Na esquerda está a imagem resultante da quarta etapa e na direita o resultado da conversão da mesma para tons de cinza

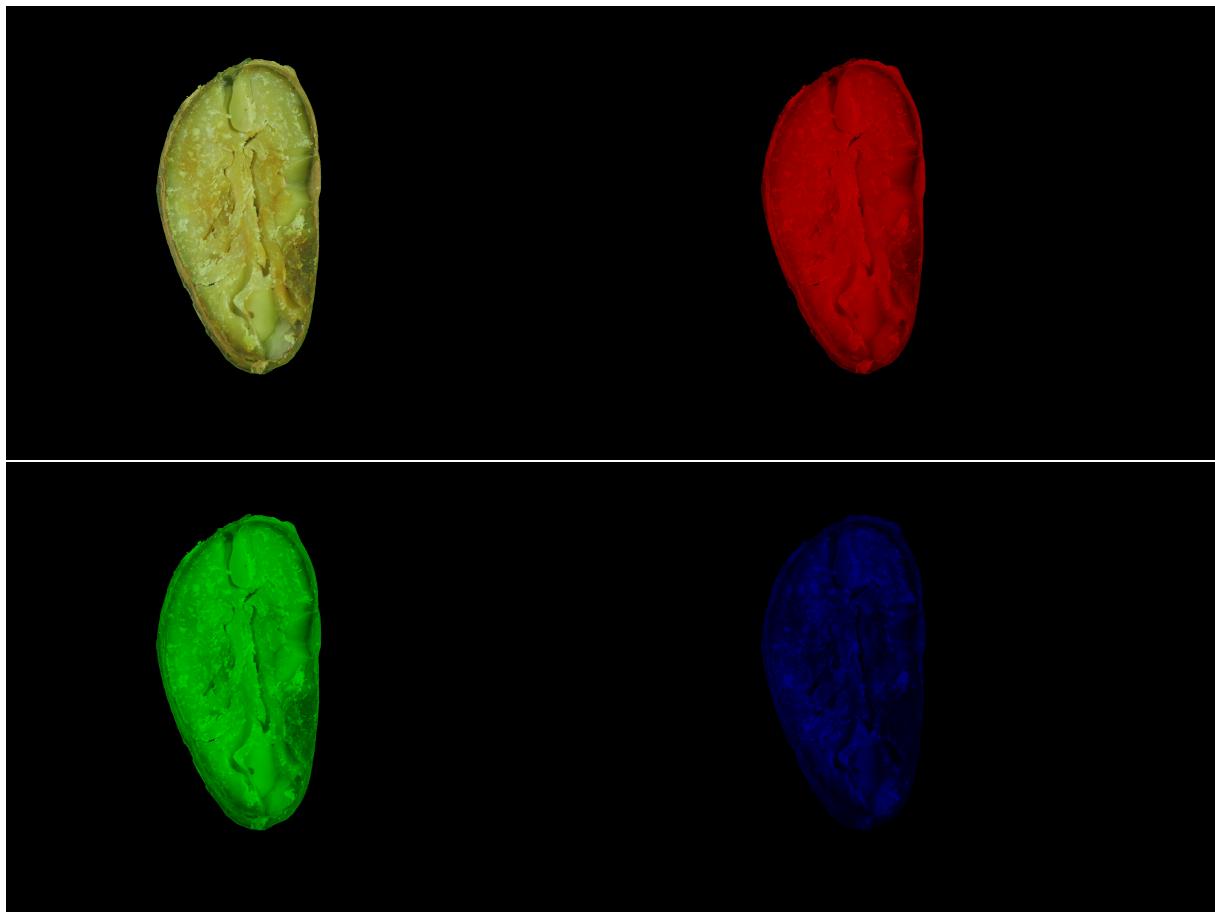


Fonte: Autoria própria

4.2.1.6 Etapa 6 - Extração das Camadas de Cores

A sexta etapa, exibida na Figura 24, consiste na extração de cada uma das camadas de cores RGB, da imagem obtida na Etapa 4, para a extração das características de cores.

Figura 24 – Esquerda Superior: a imagem resultante da Etapa 4; direita superior: a cama vermelha isolada de tal imagem; esquerda inferior: a cama verde isolada; e direita inferior: a cama azul isolada



Fonte: Autoria própria

4.2.2 Método B - Recuperação de Amêndoas

A segunda metodologia para o processamento das imagens (ou Método B) foi baseada no primeiro método, contendo alguns passos a mais que efetuados com a intenção de recuperar o dano causado durante a eliminação do plano de fundo.

O Método A foi satisfatório na eliminação do plano de fundo e dos objetos não-amêndoas entretanto, algumas amêndoas foram danificadas. Com isso em mente, objetiva-se a recuperação das áreas danificadas com as aplicações de técnicas extras.

Além das etapas descritas existem cinco outras que são idênticas às do método A, sendo: 1, 2 e 3 equivalentes às de mesmas numerações e 8 e 9 iguais às 5 e 6, respectivamente.

4.2.2.1 Etapa 4 - Inversão da Imagem Binarizada

Esta parte consiste na inversão da imagem do resultado do passo anterior, como ilustrada na Figura 25. Esta é a primeira etapa do processo de recuperação dos danos interiores à amêndoas.

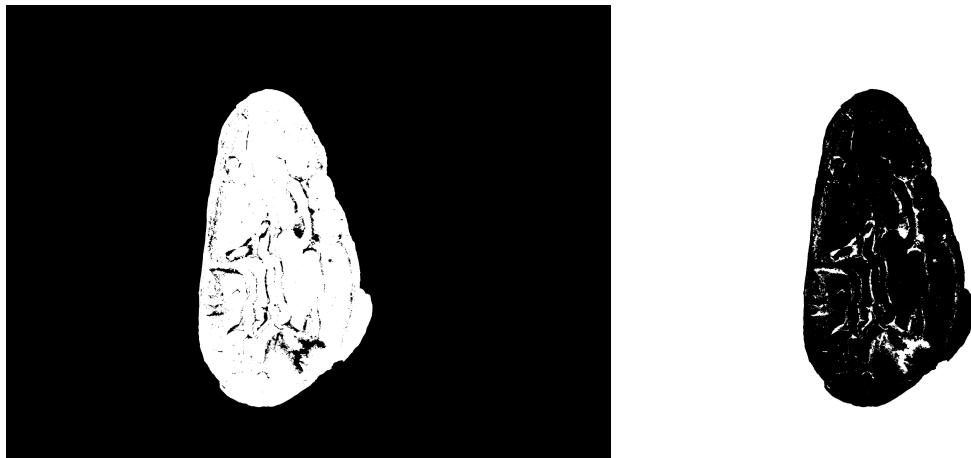
Figura 25 – Ilustração da primeira inversão de imagem, para a amêndoas Branca Chapada 34, no segundo método



Fonte: Autoria própria

A Figura 25, por possuir poucos danos causados, não ilustra bem o objetivo deste processo adicional e, com o intuito de ilustrar melhor, outra amêndoas Branca Chapada, a semente 40, também será utilizada para ilustração do processo. A aplicação desta etapa no processamento da amêndoas 40 pode ser observada na Figura 26, onde fica claro os danos interiores causados no processo de remoção do plano de fundo.

Figura 26 – Ilustração da primeira inversão de imagem, para a amêndoа Branca Chapa 40, no segundo método



Fonte: Autoria própria

4.2.2.2 Etapa 5 - Recuperação de Danos Internos

É nesta etapa que a recuperação acontece, ao se aplicar o mesmo processo descrito na Seção 4.2.1.3, para se preservar somente o segmento com maior área, que neste caso será o plano de fundo e, desta forma, reincluir todo o interior da amêndoа na máscara que será aplicada, como ilustrado na Figura 27.

Figura 27 – Ilustração da segunda aplicação do método baseado em watershed, para eliminação de danos interiores, na amêndoа 34



Fonte: Autoria própria

O processo aplicado na amêndoа 40, onde é mais visível, pode ser observado na Figura 28, onde toda a área branca no interior da amêndoа, antes do processamento,

seria perdida na aplicação da máscara.

Figura 28 – Ilustração da segunda aplicação do método baseado em watershed, para eliminação de danos interiores, na amêndoa 40

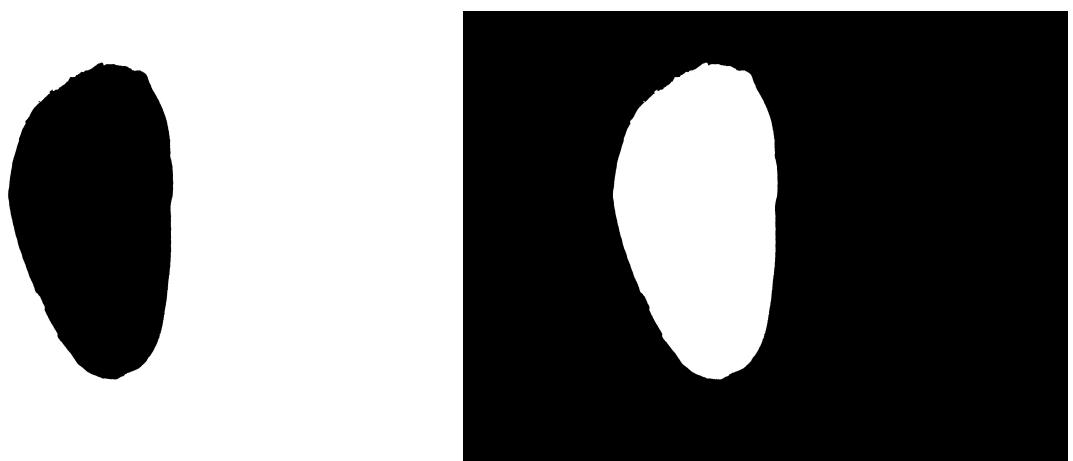


Fonte: Autoria própria

4.2.2.3 Etapa 6 - Re-inversão da Imagem

Este processamento consiste na inversão da imagem, obtendo-se assim a máscara que será aplicada na imagem original, como ilustrado na Figura 29. A imagem resultante será utilizada tal qual a imagem resultante na etapa três do primeiro método, descrita na Seção 4.2.1.3.

Figura 29 – Ilustração da segunda inversão durante o segundo método, aplicada na amêndoa Branca Chapada 34



Fonte: Autoria própria

4.2.2.4 Etapa 7 - Aplicação de Máscara

A etapa sete, tal como o passo quatro do Método A, descrita na Seção 4.2.1.4, consiste na aplicação da imagem obtida no algoritmo anterior como máscara na imagem original, preservando somente a área de cor branca da máscara. A Figura 30 ilustra a diferença nos resultados das aplicações das máscaras entre o primeiro método e o segundo, para a amêndoia 40.

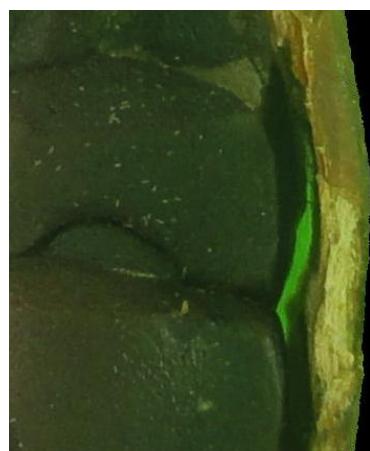
Figura 30 – A esquerda a máscara do Método A aplicado e na direita a do Método B, resultando em uma amêndoia menos danificada



Fonte: Autoria própria

É essencial ter em mente que, caso a amêndoia tenha alguma fissura ou buraco interno em que o plano de fundo fique visível, este será recuperado no processo e irá para a análise, como ilustrado na Figura 31.

Figura 31 – Parte do plano de fundo recuperado em uma amêndoia com uma fissura



Fonte: Autoria própria

4.3 Descritores para a Classificação de Amêndoas de Caú

Existem diversos descritores de características de imagens e, para o modelo aqui proposto, foram-se utilizados descritores de textura, como descritos na Seção 3.3.1, cor, como explorados na Seção 3.3.3 e estrutura, apresentados na Seção 3.3.2. Tais descritores foram selecionados devidos aos resultados interessantes observados na literatura e aos resultados obtidos em testes efetuados durante a criação deste modelo. O Algoritmo 1 apresenta os códigos utilizados para o cálculo das características em questão.

Algorithm 1 Algoritmo para o cálculo das médias das camadas de cores das amêndoas

```

1 %Extraindo as medias das cores
2 fprintf('Cores\n');
3 for i=1:nfiles
4     fprintf('%s\n',imagefiles_p8(i).name);
5     totalCinza = int64(0);
6     totalAzul = int64(0);
7     totalVermelha = int64(0);
8     totalVerde = int64(0);
9     Ip8 = images_p8{i};
10    Ip7 = images_p7{i};
11    for j=1:linhas
12        for k=1:colunas
13            if(Ip8(j,k) ≠ 0) %media do cinza
14                totalCinza = totalCinza + int64(Ip8(j,k));
15            end
16            if((Ip7(j,k,1) ≠ 0) && (Ip7(j,k,2) ≠ 0) && (Ip7(j,k,3) ≠ ...
17                0))%se nao for bg
18                totalVermelha = totalVermelha + int64(Ip7(j,k,1));
19                totalVerde = totalVerde + int64(Ip7(j,k,2));
20                totalAzul = totalAzul + int64(Ip7(j,k,3));
21            end
22        end
23    end
24    mediaCinza = round(totalCinza/areaTotal);
25    mediaVermelha = round(totalVermelha/areaTotal);
26    mediaVerde = round(totalVerde/areaTotal);
27    mediaAzul = round(totalAzul/areaTotal);
28
29    matFeatures(i, 2) = mediaCinza;
30    matFeatures(i, 3) = mediaVermelha;
31    matFeatures(i, 4) = mediaVerde;
32    matFeatures(i, 5) = mediaAzul;
33 end

```

A área foi calculada através do somatório de todos os pixels pertencentes à amêndoa, como apresentado no Algoritmo 2, obtidos a partir da imagem no passo cinco da Seção 4.2.1, como disposto na Figura 23.

Algorithm 2 Algoritmo para o cálculo da área da amêndoaa

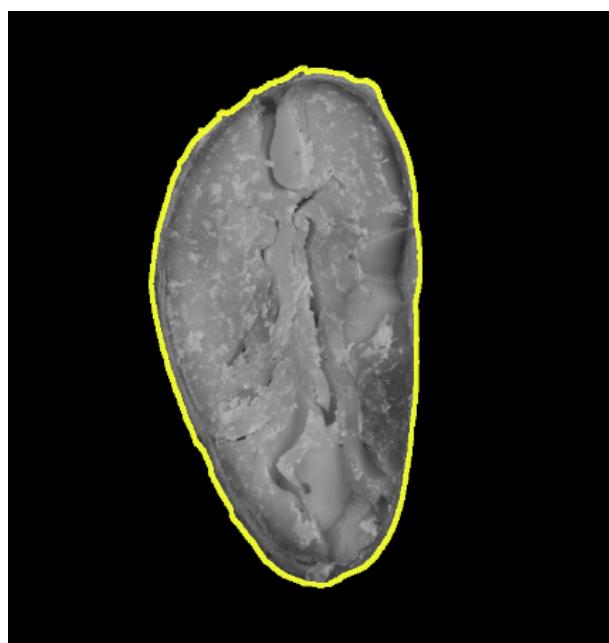
```

1 fprintf('Area\n');
2 for i=1:nfiles
3     fprintf('%s\n',imagefiles_p8(i).name);
4     areaTotal = 0;
5     I = images_p8{i};
6     for j=1:linhas
7         for k=1:colunas
8             if(I(j,k) ≠ 0) %se nao for bg
9                 areaTotal = areaTotal + 1;
10            end
11        end
12    end
13    matFeatures(i, 1) = areaTotal;
14 end

```

O perímetro foi calculado utilizando um algoritmo em MATLAB especificamente implementado para este cálculo. O Algoritmo 3 apresenta parte do código para tanto, e só leva em conta as bordas exteriores à imagem, como podemos observar na Figura 32. Esta limitação do perímetro externo foi intencionalmente programada para prevenir eventuais buracos dentro da semente, causados por acontecimentos naturais ou criados durante o processamento da imagem, fossem considerados no cálculo.

Figura 32 – Ilustração do funcionamento do algoritmo para a extração do perímetro das amêndoas



Fonte: Autoria própria

Algorithm 3 Algoritmo principal para o cálculo do perímetro externo da amêndoа

```
1
2 %perimetro
3 %aux_perimetro() é uma função recursiva aplicada a todos os pixels ...
4 %da vizinhança
5 fprintf('Perímetro\n');
6 for k = 1:nfiles
7     fprintf('%s\n',imagefiles_p8(k).name);
8
9     metaMat = zeros(linhas, colunas);
10    perimetro = 0;
11    for i=1:linhas %organizando a meta matriz
12        for j=1:colunas
13            if(images_p8{k}(i,j) ≠ 0)
14                metaMat(i,j) = 1;
15            end
16        end
17        perim = 0;
18        for i=1:linhas %organizando a meta matriz
19            for j=1:colunas
20                if(metaMat(i,j) ≠ 0)
21                    perim = aux_perimetro(i, j);
22                    break;
23                end
24            end
25        end
26
27        for i=1:linhas
28            for j=1:colunas
29                if(metaMat(i,j) == 2)
30                    perimetro = perimetro + 1;
31                end
32            end
33        end
34        matFeatures(k, 6) = perimetro;
35    end
```

5 Resultados e Discussões

Neste capítulo serão apresentado e discutidos os frutos deste trabalho. A base de imagens de amêndoas classificadas na prova de corte será explorada na Seção 5.1.1, outras versões de *datasets* criados a partir do original serão apresentados nas Seções 5.1.2.1, 5.1.2.2, 5.1.3.1, 5.1.3.2, 5.1.3.3 e 5.1.3.4, totalizando sete bancos de imagens, todos com 1400 figuras. O processo de criação da ANN para a classificação é apresentado na Seção 5.2.1, o estudo das combinações de características para a criação do sistema de visão computacional é apresentada na Seção 5.2.2 e o modelo final é explorado na Seção 5.3.

5.1 *Dataset* de imagens de cacau classificadas na prova de corte

Um dos frutos deste trabalho é um banco de imagens, de amêndoas de cacau previamente classificadas na prova de corte, cujo processo de desenvolvimento foi descrito na Seção 4.1, contendo 1400 imagens de 14 classes diferentes, 100 imagens de cada classe. Além disso, como explorado anteriormente, as imagens foram classificadas por especialistas do Centro de Inovação do Cacau (CIC), seguindo a norma regulativa [Agricultura \(2008\)](#).

As amêndoas foram separadas em 14 classificações para integrar as bases, segundo as suas classificações possíveis em relação às cores e compartimentações, sendo as classes: Aglutinada, Achatada, Ardósia Chapada, Ardósia Compartimentada, Branca Chapada, Branca Compartimentada, Marrom Chapada, Marrom Compartimentada, Mofada, Quebradiça, Parcialmente Violeta Compartimentada, Parcialmente Violeta Chapada, Violeta Chapada e Violeta Compartimentada.

Além da versão original, sem processamento, outras versões do *dataset* também serão disponibilizadas para a comunidade científica. Na Seção 5.1.1 será apresentada a base em sua versão original; na Seção 5.1.2.1 será apresentado o resultado da aplicação do processamento utilizando o primeiro método nas imagens, descrito na Seção 4.2.1; na Seção 5.1.2.2 o resultado da aplicação do segundo método, descrito na Seção 4.2.2; uma versão contendo todas as imagens dispostas no *dataset* disposto na Seção 5.1.2.1, centralizadas e encaixadas no menor retângulo possível que encaixe cada amêndoa individualmente, apresentado na Seção 5.1.3.1; todas as amêndoas centralizadas e enquadradas no menor retângulo que encaixe todas as amêndoas, resultando em todas as imagens com as mesmas dimensões, disposto na Seção 5.1.3.2; um banco de imagens,

com as amêndoas dispostas na Seção 5.1.2.2, com cada amêndoas individualmente encaixada no menor retângulo possível; e a Seção 5.1.3.4 apresenta um *dataset*, construído a partir da base apresentada na Seção 5.1.2.2, em que todas as imagens foram encaixadas no menor retângulo possível que caibam todas, resultando em uma mesma resolução para todas as figuras. As bases de imagens disponibilizadas contém as figuras antes de suas conversões para tons de cinza ou das extrações das camadas de cores.

A título de comparação das aplicabilidades dos diferentes *datasets* disponibilizados, o teste do uso de memórias associativas *fuzzy* para a classificação de imagens foi efetuado com colaboração de um grupo de pesquisadores da Unicamp e, para os testes efetuados, o resultado se utilizando o *dataset* descrito em 5.1.3.2 ofereceu melhor precisão do que quando foi-se utilizada a base original, o que era esperado, visto que o posicionamento dos objetos influencia os testes. Os colaboradores envolvidos estão identificados nos agradecimentos.

Um exemplo de cada classe será disposto em cada *dataset* com o intuito de facilitar a visualização da composição de cada base de imagens e de suas diferenças.

5.1.1 *Dataset* Original

Está é a versão original do *dataset*, cujo processo de construção se encontra na Seção 4.1, apresentando as imagens como foram capturadas, sem nenhum processamento pós-captura. É importante notar que algumas imagens apresentaram diferença no brilho de captura, como observável na Figura 33. Isso aconteceu devido à própria disposição da iluminação interna ser alterada com as sementes, que apresentavam diferentes formatos e cores, e pelas configurações da máquina de captura, cujos sensores de iluminação não eram configuráveis. Entretanto, estes nuances nas iluminações das imagens eram esperados e não tornam a base inútil para a classificação, como observamos no modelo de classificação final e em bases de imagens presentes na literatura.

Figura 33 – Amêndoas como apresentadas no *dataset* original, uma Branca chapada, na esquerda, e uma Branca Compartimentada na direita.



Fonte: Autoria própria

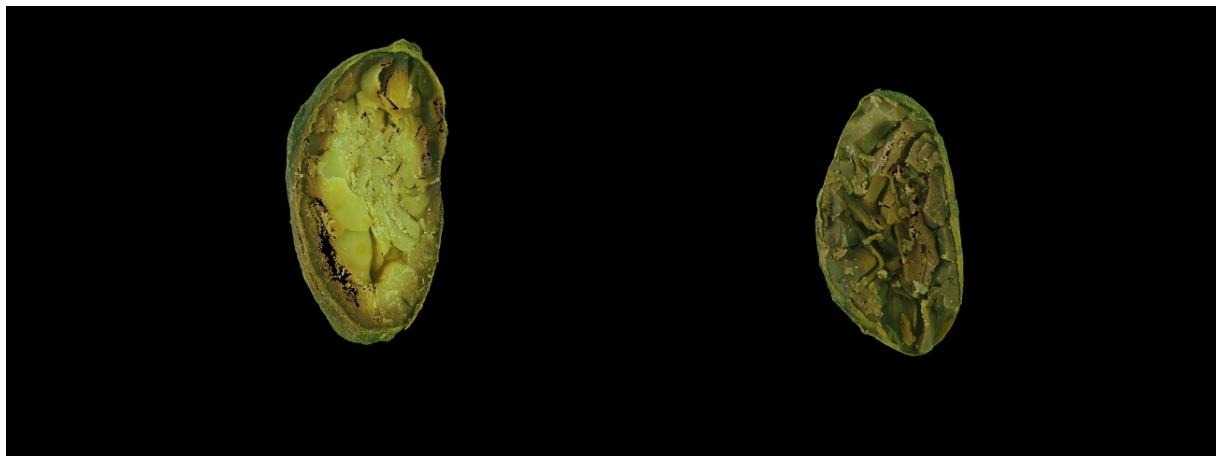
5.1.2 Dataset Sem Plano de Fundo

Duas versões, seguindo os processos descritos nas Seções 4.2.1 e 4.2.2, serão apresentados nas Seções 5.1.2.1 e 5.1.2.2 e também estão disponibilizados.

5.1.2.1 Versão 1 - Processado com Método A

Este *dataset* é o resultado do processamento da base original através do método descrito na Seção 4.2.1. O método utilizado para a construção desta versão da base causou danos a algumas sementes, como observamos na Figura 34, mas estes danos não removeram as características classificatórias das sementes, como o mofo e a cor dos interiores.

Figura 34 – Exemplo de amêndoas do *dataset* processado pelo método descrito na Seção 4.2.1. Uma sementes Branca Chapada na esquerda e uma branca compartimentada na direita.

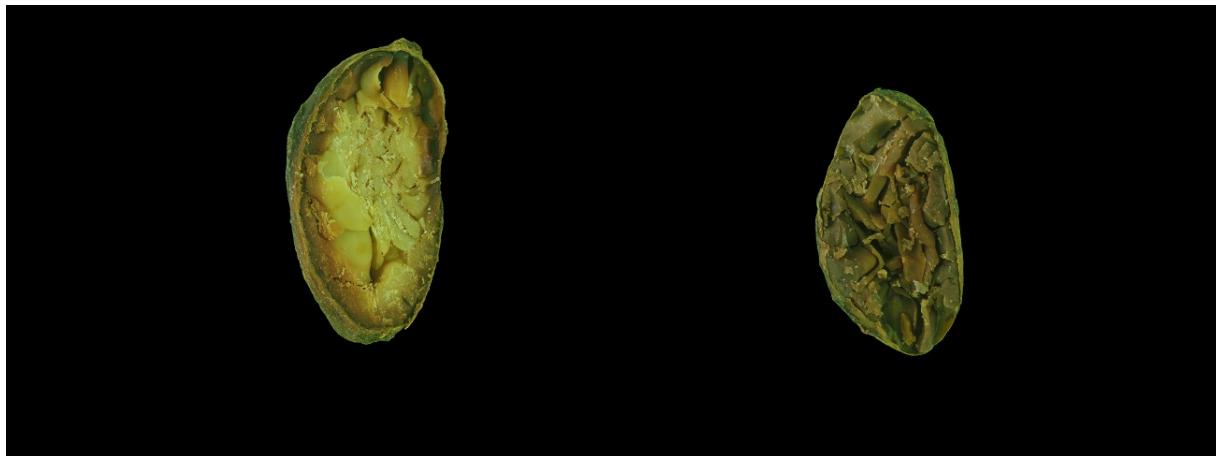


Fonte: Autoria própria

5.1.2.2 Versão 2 - Processado com Método B

O método descrito na Seção 4.2.2 foi utilizado para a construção desta versão da base. O objetivo desta, foi o de fornecer uma versão da base processada em que os danos causados às amêndoas no método anterior, como observado na Seção 5.1.2.1, fossem recuperados. Os danos foram recuperados porém, como descrito na Seção 4.2.2, e apresentado na Figura 31, se alguma parte do plano de fundo puder ser vista dentro do perímetro da amêndoa, seja por uma rachadura ou um buraco na amêndoa, este também será recuperado, causando com que uma parte do plano de fundo pertença à imagem. A Figura 35, em que foram utilizadas as mesmas amêndoas da base original que são apresentadas na Figura 34, apresenta exemplos de imagens deste *dataset* e da recuperação de danos no interior.

Figura 35 – *Dataset* construído com o Método B, descrito na seção 4.2.2. Uma amêndoas Branca Chapada na esquerda e uma Branca Compartimentada na direita.



Fonte: Autoria própria

5.1.3 Dataset Com as Amêndoas Centralizadas e Enquadradadas

Versões das bases apresentada nas Seções 5.1.2.1 e 5.1.2.2, com as amêndoas movidas para o centro das imagens e outras com as sementes encaixadas no menor retângulo que as caibam, também são disponibilizadas. Tais versões serão descritas nas Subseções 5.1.3.1, 5.1.3.2, 5.1.3.3 e 5.1.3.4. Estas versões foram disponibilizadas com a intenção de abranger o máximo de público possível, visto que nem todos os pesquisadores tem as habilidades de processamento de imagens desenvolvidas, aumentando assim a abrangência dos resultados deste trabalho. Outra motivação importante, e também um gatilho para a construção destas versões do *dataset*, foram testes, efetuados com a ajuda de colaboradores, se utilizando de memórias associativas fuzzy, que forneceram uma acurácia maior nos resultados, quando as imagens descritas na Seção 5.1.3.2 foram utilizadas, quando se comparado com a utilização das imagens da base original.

5.1.3.1 Versão 1 - Processado com Método A e Enquadrado Individualmente

Este *dataset* é construído a partir do recorte das amêndoas apresentadas na base da Seção 5.1.2.1, onde todas as amêndoas foram recortadas, de modo a ficarem no menor retângulo possível que as caibam. O processo foi feito por um algoritmo desenvolvido para MATLAB e, devido à diferença nas formas e posicionamentos das amêndoas, as figuras desta base possuem altura e largura de imagens variáveis. Exemplos das imagens resultantes desta base podem ser observados na Figura 36.

Figura 36 – Exemplos de imagens, para as amêndoas do *dataset* da Seção 5.1.2.1, recortadas no menor retângulo possível que as caibam.

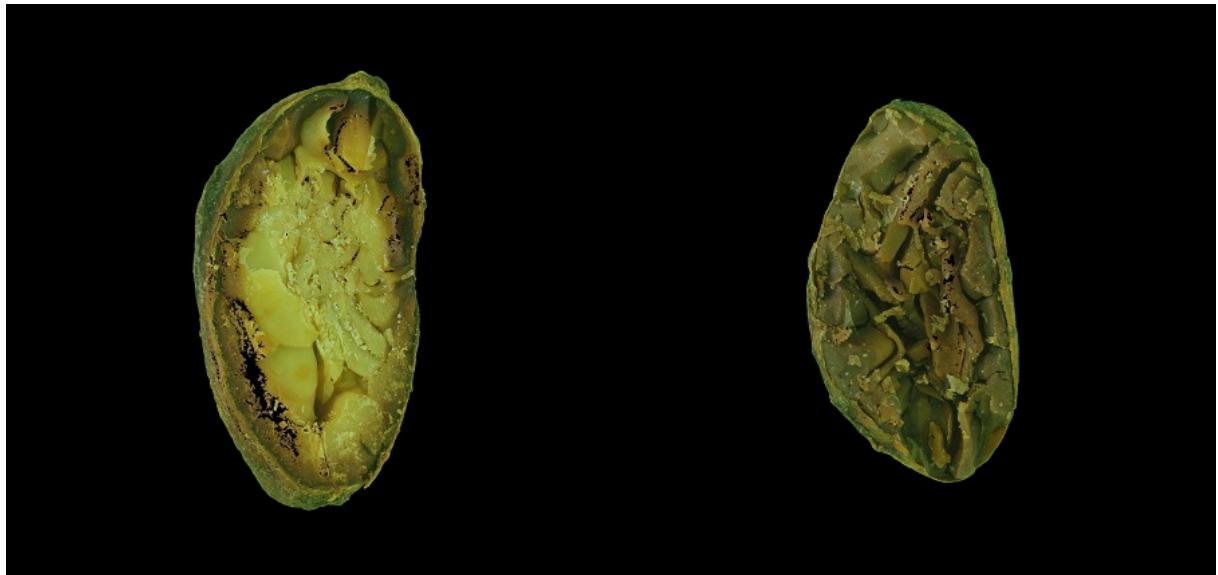


Fonte: Autoria própria

5.1.3.2 Versão 2 - Processado com Método A e Enquadradado Uniformemente

Este *dataset* se constitui das amêndoas apresentadas na base descrita na Seção 5.1.2.1, todas centralizadas no menor retângulo possível que encaixe todas as sementes. Para a obtenção de tal retângulo, todas as imagens da base foram algorítmicamente analisadas e a maior altura e maior largura presentes foram selecionadas para a construção de um retângulo em que todas as amêndoas foram centralizadas. Desta forma, como observado na Figura 37, todas as imagens desta base possuem a mesma altura e largura.

Figura 37 – Sementes do método 1 recortadas e centralizadas



Fonte: Autoria própria

5.1.3.3 Versão 3 - Processado com Método B e Enquadrado Individualmente

Esta versão se constitui das amêndoas pertencentes ao *dataset* na Seção 5.1.2.2, recortadas no menor retângulo possível que cabem. Foi-se utilizado os mesmos algoritmos para a construção do *dataset* da Seção 5.1.3.1, mudando somente da base de imagens em que tais algoritmos foram aplicados. A Figura 38 exibe imagens desta versão e, assim como na base descrita na Seção 5.1.3.1, esta também possui altura e largura de imagens variáveis. Comparando-se as Figuras 36 e 38 fica-se claro o resultado do processo de recuperação de danos nas amêndoas.

Figura 38 – Amêndoas, do *dataset* construído com o segundo método, recortadas e centralizadas no menor retângulo individual que as caibam

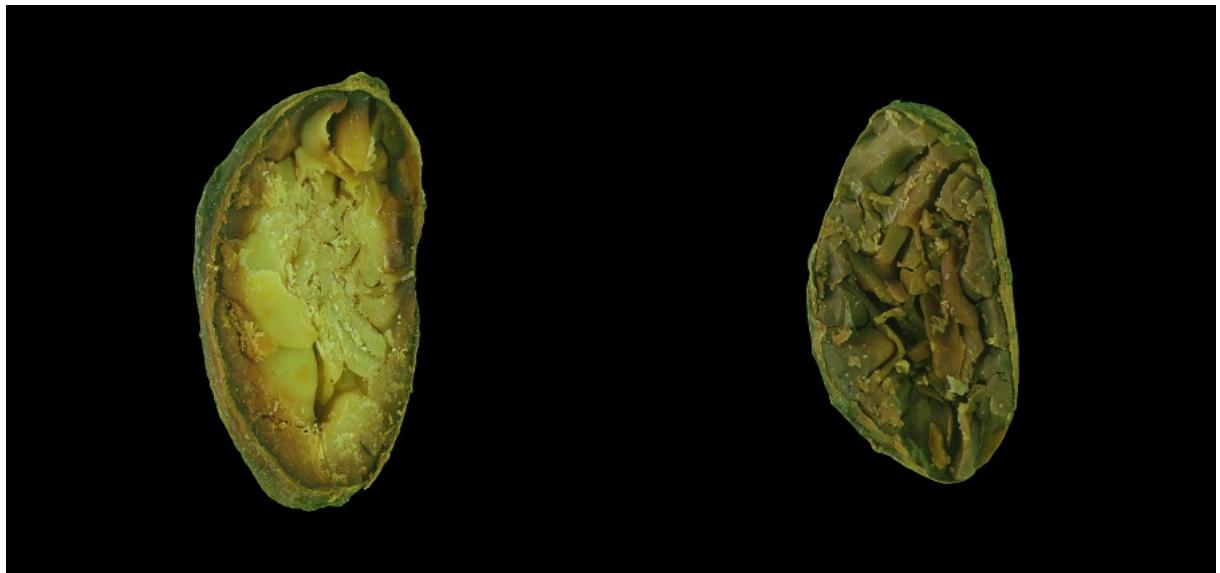


Fonte: Autoria própria

5.1.3.4 Versão 4 - Processado com Método B e Enquadrado Uniformemente

As amêndoas do *dataset* construído com o segundo método foram analisadas e centralizadas no menor retângulo que encaixem todas as sementes. Os algoritmos utilizados para esta construção foram os mesmos dos utilizados para a construção da base descrita na Seção 5.1.3.2, modificando-se somente as imagens em que foram aplicados. Assim como o *dataset* da Seção 5.1.3.2, todas as imagens desta base possuem as mesmas largura e altura. A Figura 39 apresenta imagens de amêndoas deste conjunto.

Figura 39 – Amêndoas, do segundo método, centralizadas no retângulo construído a partir da maior largura e maior altura de todas as sementes



Fonte: Autoria própria

5.2 Modelo para a Classificação das Amêndoas

O modelo para a classificação das classes das amêndoas na prova de corte foi elaborado se utilizando de redes neurais perceptron multicamada, visto a sua ampla presença em problemas de classificações similares na literatura e, como entrada de tal rede, uma combinação específica de descritores de características das imagens foi estudado e proposto ([NANDI et al., 2014](#); [SAVAKAR, 2012](#); [PATIL et al., 2011](#); [AL-MARAKEBY et al., 2013](#); [HAIDAR et al., 2012](#); [ZHANG et al., 2016](#); [LOURO et al., 2006](#)).

Um estudo preliminar, se utilizando parte da base de dados com a metodologia proposta aqui, se encontra em [Santos et al. \(2018\)](#), onde é apresentada o processamento de imagens descrito na Sessão 4.2.1, para a extração de características e teste das combinações de tais descritores para um sistema de classificação. O processo para a definição das configurações da rede neural a ser utilizada, seguindo a mesma metodologia de [Santos et al. \(2018\)](#), será apresentado na Seção 5.2.1, agora para a base completa. Além disso, o estudo da combinação de características será refeito, visto que a base de imagens utilizadas se alterou, e será apresentado na Seção 5.2.2.

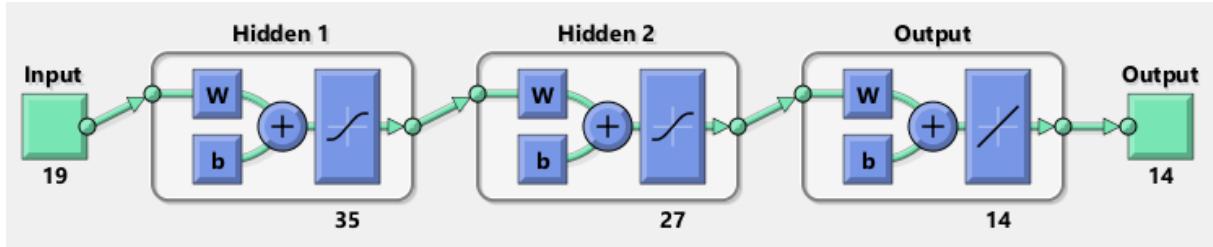
5.2.1 Configuração de Uma Rede Perceptron Multicamada para a classificação

Para este novo estudo da configuração de rede perceptron multicamada, as configurações descritas em [Santos et al. \(2018\)](#) foram mantidas para um teste inicial, visto os bons resultados obtidos no estudo em questão, sendo: a taxa de aprendizado de 10^{-1} , número máximo de épocas de 10^3 , erro máximo desejado de 10^{-5} , calculado através do erro quadrático médio, e treinamento com algoritmo de retro-propagação. A base de imagem foi divida de forma aleatória e por classe, sendo, das imagens de cada classe, 70% utilizadas para treinamento, 15% para validação e 15% para testes. Tais configurações foram obtidas através de diversos testes efetuados e de configurações similares presentes na literatura.

Definidas as configurações anteriores, tendo em vista a mudança da base de dados desde o estudo preliminar, será feito uma análise da configuração da quantidade de neurônios e de camadas na rede que proveem melhores resultados para o modelo de classificação. Os testes em questão foram efetuados ao se testar a acurácia obtida na rede configurada com uma quantidade de neurônios na primeira camada variando de um à 50 e, uma vez observado a quantidade de neurônios que resultaram em uma melhor acurácia, fixando tal quantidade e testando, com o mesmo método, as camadas interiores.

O modelo da MLP para a base completa se constituiu de duas camadas escondidas, cujos estudos para suas obtenções serão apresentados nas Seções [5.2.1.1](#) e [5.2.1.2](#), com as configurações descritas no início desta seção e combinações de texturas descritas na Seção [5.2.2](#). Adicionalmente, para os testes a serem efetuados na determinação da quantidade de neurônios das camadas, será utilizado o conjunto de características que ofereceu melhor acurácia para a construção da RNA no estudo apresentado em [Santos et al. \(2018\)](#), que foi de 99,73%, sendo estas características: os quatorze descritores de textura de Haralick, apresentados na Seção [3.3.1](#), as médias das camadas vermelhas, verdes, azuis e cinzas, apresentadas na Seção [3.3.3](#) e a área da amêndoa, apresentada na Seção [3.3.2](#). A topologia final da MLP pode ser observada na Figura [40](#), contendo 35 neurônios na primeira camada oculta e 27 na segunda, resultando em uma precisão de 99,64%.

Figura 40 – Topologia Final da Rede MLP

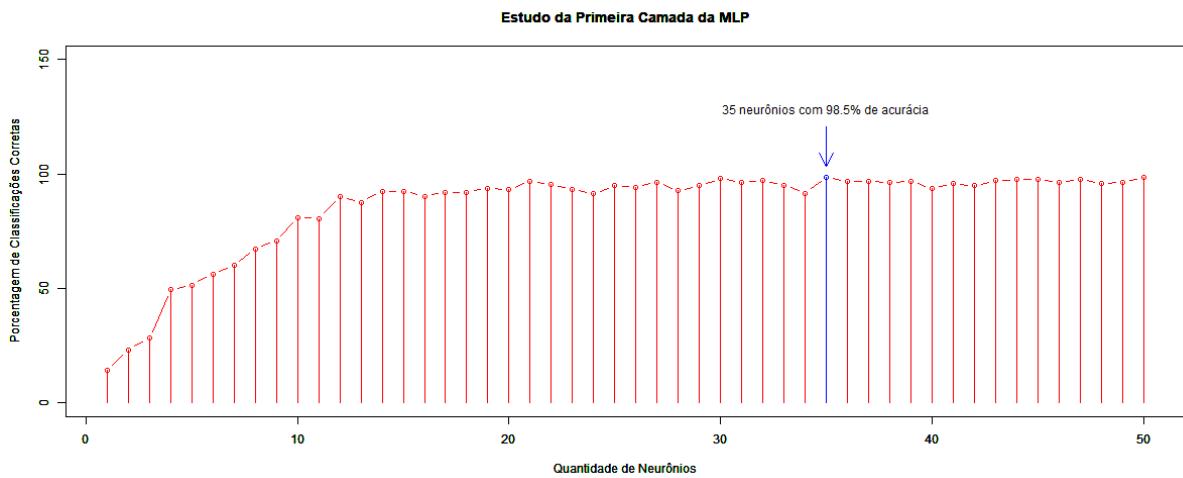


Fonte: MATLAB Neural Network Toolbox

5.2.1.1 Primeira Camada da MLP

O processo de definição da quantidade de neurônios da primeira camada, como exibido na Figura 41, foi o de treinar redes neurais MLP com uma quantidade de neurônios variando de 1 a 50, mantendo as outras configurações constantes.

Figura 41 – Estudo de Acurácia e Definição de Neurônios da Primeira Camada



Fonte: Autoria Própria

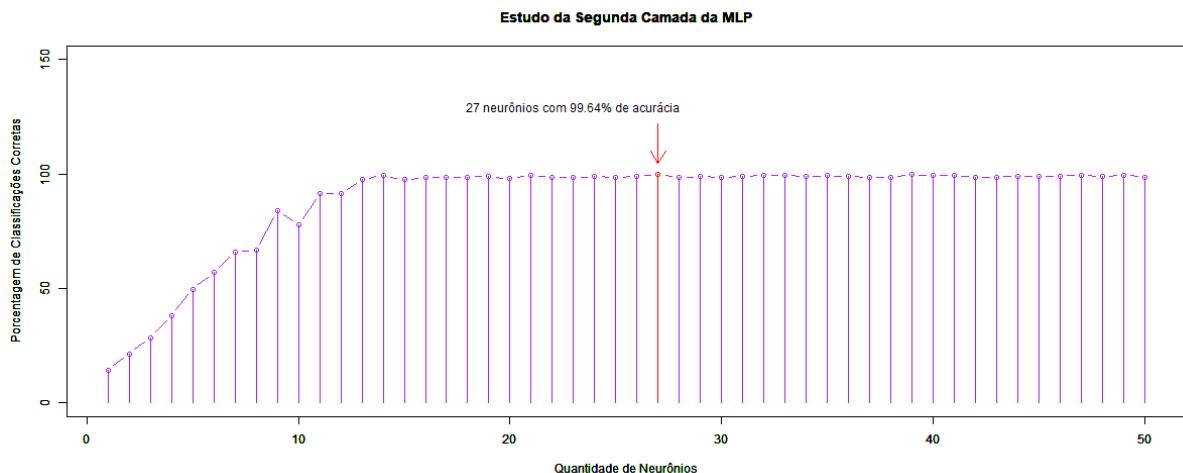
Como exibido na Figura 41, a maior acurácia foi obtida ao se utilizar 35 neurônios na primeira camada, resultando em uma acurácia de 98,5%.

5.2.1.2 Segunda Camada da MLP

O processo de definição da quantidade de neurônios na segunda camada foi-se fixar a quantidade de neurônios que ofereceu melhor precisão na primeira camada (35 neurônios resultando em 98,5%) e, assim como feito para a primeira, treinar a rede neural com uma quantidade de neurônios variando de um à 50. O estudo da segunda

camada foi efetuado para se melhorar a precisão da rede, tendo-se em mente que o estudo preliminar disposto em [Santos et al. \(2018\)](#) alcançou uma precisão de 99,73% para uma configuração de MLP específica. A Figura 42 exibe as acurácia obtidas para cada um dos treinamentos feitos com as redes neurais.

Figura 42 – Estudo de Acurácia e Definição de Neurônios da Segunda Camada



Fonte: Autoria Própria

A melhor acurácia obtida foi 99,64%, com 27 neurônios na segunda camada. O estudo de camadas adicionais para a rede neural não foi efetuado pois a complexidade da rede aumentaria significativamente e as melhorias possíveis na acurácia não são tão grandes e, além disso, o resultado obtido está muito similar ao alcançado em [Santos et al. \(2018\)](#). Desta forma, a configuração final de neurônios da MLP que será utilizada para o modelo de classificação conterá 35 neurônios na primeira camada e 27 na segunda, como exibido anteriormente na Figura 40.

5.2.2 Combinações de descritores de cor, estrutura e textura para a análise

A rede MLP, obtida nos estudos descritos na Seção 5.2.1, foi treinada com diversas combinações das características extraídas das imagens descritas na Seção 3.3. Os descritores de características foram todos extraídos das imagens processadas seguindo o método descrito na Seção 4.2.1. O estudo das combinações das características, assim como efetuado em [Santos et al. \(2018\)](#), foi efetuado

Um total de 16 análises, dispostas na Tabela 5, foram feitas, onde RGB Means significa as médias de cores das camadas vermelha, verde e azul, GS Mean significa

a média de cor da imagem em tons de cinza, Ar significa a área da amêndoa e Pe o perímetro da mesma.

Tabela 5 – Acurárias resultantes das combinações das características das imagens com a rede MLP

Características Utilizadas	Acurácia Obtida (%)
14H	56,64
14H + Ar	60,71
14H + Pe	61,00
14H + RGB Means	81,79
14H + GS Mean	66,00
14H + Ar + GS Mean	98,21
14H + Ar + RGB Means	99,14
14H + Ar + Pe	65,21
14H + RGB Means + Pe	88,29
14H + RGB Means + GS Mean	80,79
14H + GS Mean + Pe	79,50
14H + Ar + RGB Means + GS Mean	99,64
14H + Ar + RGB Means + Pe	98,50
14H + Ar + GS Mean + Pe	96,00
14H + RGB Means + GS Mean + Pe	87,71
14H + Ar + RGB Means + GS Mean + Pe	99,00

Analizando-se a Tabela 5, observa-se que a melhor acurácia foi obtida quando a MLP foi treinada utilizando os quatorze descritores de textura de Haralick, as médias das cores das camadas vermelha, verde e azul, a média de cor da imagem em tons de cinza e a área da amêndoa, assim como no estudo preliminar presente em Santos et al. (2018).

Além disso, o perímetro da amêndoа foi uma característica cuja presença no modelo resultou em uma acurácia final pior do que se o modelo fosse treinado sem o mesmo, quando todas as características estavam presentes. Esta ocorrência era esperada devido a esta mesma ocorrência ter sido observada em Santos et al. (2018) e pelo fato de que as novas classes de amêndoas adicionadas na base posteriormente ao estudo em questão não terem discrepâncias perceptíveis no perímetro das amêndoas. Ainda com esta ocorrência sendo esperada, os questionamentos quanto à possíveis ligações entre os perímetros das amêndoas e suas classificações ainda é pertinente e necessita de estudos futuros para um melhor entendimento deste comportamento.

Outro acontecimento bastante interessante, e também vinculado ao perímetro da amêndoа, foi o de que a análise que consta das quatorze características de Haralick com o perímetro da amêndoа resultou em um modelo com melhor acurácia do que somente com os descritores de Haralick, estas sendo 61,00% e 56,64%, respectivamente. Este acontecimento não foi observado quando esta mesma análise foi efetuada em Santos et al. (2018), onde tais análises resultaram em acurárias de 58,18% e 67,18%, respectivamente. Adicionalmente, com exceção no uso de todas as características ao mesmo tempo, a adição do perímetro melhorou as acurárias finais nos modelos descritos na Tabela 5, acontecimento contrário ao observado no estudo anterior, revelando assim, juntamente com a mudança na topologia da rede, os impactos causados quando se altera a base de imagens utilizada.

5.3 Modelo Final para a Classificação

Observando-se as acurárias obtidas e discutidas na Seção 5.2.2, utilizadas com a configuração e topologia de uma MLP descrita na Seção 5.2.1, tem-se, como modelo final para a classificação de amêndoas da prova de corte obtidas segundo as condições descritas na Seção 4.1.3 e processadas seguindo a metodologia descrita na Seção 4.2.1, uma rede neural artificial perceptron multicamada, com 35 neurônios na primeira camada oculta, 27 neurônios na segunda camada oculta, com taxa de aprendizado de 10^{-1} , número máximo de épocas de 10^3 , erro máximo desejado de 10^{-5} , calculado através do erro quadrático médio, e treinamento com algoritmo de retro-propagação, treinada com os quatorze descritores de textura de Haralick, médias das cores nas camadas vermelha, verde e azul, média das cores da imagem em tons de cinza e a área a amêndoа, utilizando-se 70% das imagens de cada classe para treinamento, 15% para validação e 15% para testes, todas estas sendo escolhidas aleatoriamente por classe, resultando em uma acurácia final de 99,64%.

6 Considerações finais

A pesquisa descrita nesta dissertação foi motivada e inspirada por uma limitação observada na execução da prova de corte. Com isso em mente, a aplicação de métodos automatizados para o auxílio a especialistas na classificação de amêndoas de cacau poderá trazer resultados comerciais e científicos formidáveis para a indústria em questão. Desta forma, este trabalho teve uma natureza embrionária e objetivou o início desta caminhada.

Os resultados obtidos nesta pesquisa foram de grande satisfação, de modo que instituições de ensino técnico e empresas locais se motivaram a continuar esta caminhada e tentar gerar frutos tecnológicos para a indústria cacaueira se utilizando deste trabalho. A inspiração destes talentos empreendedores para a criação de novas tecnologias é considerado um dos maiores frutos deste trabalho.

6.1 Principais Contribuições

É esperado que as bases de imagens resultantes desta pesquisa auxiliem outros pesquisadores que desejem estudar a prova de corte, amêndoas de cacau, classificação de imagens e diversas outras áreas da ciência.

Além disso, os Métodos A e B, descritos nas Seções [4.2.1](#) e [4.2.2](#), auxiliaram outros pesquisadores que busquem modos de processar imagens para fins parecidos com os disposto nessa pesquisa.

O protótipo para a captura de imagens e suas configurações, dispostos neste trabalho, também pode auxiliar outros pesquisadores que desejem criar *datasets* e possibilita a expansão das bases já apresentadas aqui por outras pessoas.

Por fim, é esperado que o modelo criado possibilite o desenvolvimento de mecanismos e aparatos que os utilizem para efetivamente auxiliar os especialistas que atuam na classificação de amêndoas de cacau na prova de corte.

6.2 Trabalhos Futuros

Tendo-se em mente que se trata de diversas bases de dados novas, em que a maioria dos métodos não foram testados, os horizontes científicos são extremamente amplos, com continuações como, por exemplo: a verificação da aplicabilidade de métodos não-supervisionados para a criação de um modelo, como os mapas auto-organizáveis de Kohonen; a utilização da teoria *fuzzy* para a modelagem e tratamento das imprecisões

causadas pelas classificações em variáveis linguísticas das amêndoas; a comparação de outros métodos de classificações e seus resultados quando utilizados nas diferentes versões das bases de imagens; propostas de novos métodos de pré-processamento de imagens e a avaliação da utilização de diferentes espaços de cores para tanto; além de inúmeras outras possíveis continuações.

Referências

- ADONIAS, G. de L.; REGIS, C. D. M. Avaliação de manchas de pele usando processamento de imagens. **Revista Principia**, Directory of Open Access Journals, v. 1, n. 27, p. 111–117, 2015.
- AGRICULTURA, P. e. A. Brasil. Ministério da. Regulamento técnico da amêndoa de cacau. **Diário Oficial da União, Brasília**, v. 38, 2008. Instrução Normativa.
- AGUIAR, C. B. d.; SOARES, W. d. S.; LIMA, L. A. d.; REGIS, C. D. M. Avaliação estatística dos descritores de haralick na detecção do acidente vascular cerebral isquêmico. **XXXIV SIMPÓSIO BRASILEIRO DE TELECOMUNICAÇÕES**, 2016.
- AL-MARAKEBY, A.; ALY, A. A.; SALEM, F. A. Fast quality inspection of food products using computer vision. **International Journal of Advanced Research in Computer and Communication Engineering** [1], v. 2, 2013.
- AMBRÓSIO, P. E. **Redes neurais artificiais no apoio ao diagnóstico diferencial de lesões intersticiais pulmonares**. Tese (Doutorado) — Universidade de São Paulo, 2002.
- BARRETO, J. M. Introdução às redes neurais artificiais. **V Escola Regional de Informática. Sociedade Brasileira de Computação, Regional Sul, Santa Maria, Florianópolis, Maringá**, p. 5–10, 2002.
- BIANCHI, R. A.; REALI-COSTA, A. H. O sistema de visão computacional do time futepoli de futebol de robôs. In: **Congresso Brasileiro de Automática**. [S.l.: s.n.], 2000. v. 130, p. 2156–2162.
- CATSBERG, C. M. E.; DOMMELEN, G. J. M. K.-V. Cocoa and chocolate. In: **Food Handbook**. Springer, 1990. ISBN 978-94-010-6684-6. Disponível em: <http://dx.doi.org/10.1007/978-94-009-0445-3_29>.
- GLINGANI, F. A.; AMBRÓSIO, P. E. Sistema de análise computadorizada para auxílio à detecção de lesões de mama baseado em redes neurais artificiais. In: **XXIX Congresso da Sociedade Brasileira de Computação**. [S.l.: s.n.], 2009.
- GONZALEZ, R. C.; WOODS, R. E. Digital image processing second edition. **Beijing: Publishing House of Electronics Industry**, v. 455, 2002.
- HAIDAR, A.; DONG, H.; MAVRIDIS, N. Image-based date fruit classification. In: **IEEE. Ultra Modern Telecommunications and Control Systems and Workshops (ICUMT), 2012 4th International Congress on**. [S.I.], 2012. p. 357–363.
- HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. et al. Textural features for image classification. **IEEE Transactions on systems, man, and cybernetics**, v. 3, n. 6, p. 610–621, 1973.
- KHOTANZAD, A.; LU, J.-H. Classification of invariant image representations using a neural network. **IEEE Transactions on Acoustics, Speech, and Signal Processing**, IEEE, v. 38, n. 6, p. 1028–1038, 1990.

- KILIÇ, K.; BOYACI, I. H.; KÖKSEL, H.; KÜSMENOĞLU, İ. A classification system for beans using computer vision system and artificial neural networks. **Journal of Food Engineering**, Elsevier, v. 78, n. 3, p. 897–904, 2007.
- KIM, M. H.; WEYRICH, T.; KAUTZ, J. Modeling human color perception under extended luminance levels. **ACM transactions on graphics (TOG)**, ACM, v. 28, n. 3, p. 27, 2009.
- KONDO, N.; AHMAD, U.; MONTA, M.; MURASE, H. Machine vision based quality evaluation of iyokan orange fruit using neural networks. **Computers and Electronics in Agriculture**, Elsevier, v. 29, n. 1-2, p. 135–147, 2000.
- LARESE, M. G.; NAMÍAS, R.; CRAVIOTTO, R. M.; ARANGO, M. R.; GALLO, C.; GRANITTO, P. M. Automatic classification of legumes using leaf vein image features. **Pattern Recognition**, Elsevier, v. 47, n. 1, p. 158–168, 2014.
- LOURO, A. H. F.; MENDONÇA, M. M.; GONZAGA, A. Classificação de tomates utilizando redes neurais artificiais. In: **proceedings of the II workshop de Visão Computacional, São Carlos, SP**. [S.l.: s.n.], 2006.
- MAJUMDAR, S.; JAYAS, D.; HEHN, J.; BULLEY, N. Classification of various grains using optical properties. **Canadian Agricultural Engineering**, Ottawa: The Society,[1951-2000], v. 38, n. 2, p. 139–144, 1996.
- MARENCONI, M.; STRINGHINI, S. Tutorial: Introdução à visão computacional usando opencv. **Revista de Informática Teórica e Aplicada**, v. 16, n. 1, p. 125–160, 2009.
- MATICH, D. J. Redes neuronales: Conceptos básicos y aplicaciones. **Universidad Tecnológica Nacional, México**, 2001.
- MATLAB Optimization Toolbox. 2018.
- NANDI, C. S.; TUDU, B.; KOLEY, C. Computer vision based mango fruit grading system. In: **International Conference on Innovative Engineering Technologies (ICIET'2014)**. [S.l.: s.n.], 2014. p. 1–5.
- NEITZ, J.; CARROLL, J.; YAMAUCHI, Y.; NEITZ, M.; WILLIAMS, D. R. Color perception is mediated by a plastic neural mechanism that is adjustable in adults. **Neuron**, Elsevier, v. 35, n. 4, p. 783–792, 2002.
- OLABE, X. B. Redes neuronales artificiales y sus aplicaciones. **Publicaciones de la Escuela de Ingenieros 101pp**, 1998.
- OLIVEIRA, E. M. de; LEME, D. S.; BARBOSA, B. H. G.; RODARTE, M. P.; PEREIRA, R. G. F. A. A computer vision system for coffee beans classification based on computational intelligence techniques. **Journal of Food Engineering**, Elsevier, v. 171, p. 22–27, 2016.
- OLUNLOYO, V. O.; IBIDAPO, T. A.; DINRIFO, R. R. Neural network-based electronic nose for cocoa beans quality assessment. **Agricultural Engineering International: CIGR Journal**, v. 13, n. 4, 2012.

- OYAMA, P. d. C.; RODRIGUES, E.; JORGE, L. d. C. Methodology to classify coffee beans samples through shape, colour and texture descriptors. In: IN: WORKSHOP DE VISÃO COMPUTACIONAL-WVC, 9., 2013, RIO DE JANEIRO. ANAIS... RIO DE JANEIRO: FGV 2013. **Embrapa Instrumentação-Artigo em anais de congresso (ALICE)**. [S.l.], 2013.
- PATIL, N. K.; MALEMATH, V. S.; YADAHALLI, R. M. Color and texture based identification and classification of food grains using different color models and haralick features. **International Journal on Computer Science and Engineering**, Engg Journals Publications, v. 3, n. 12, p. 3669, 2011.
- PENCUE, E. L.; LEÓN-TÉLLEZ, J. Detección y clasificación de defectos en frutas mediante el procesamiento digital de imágenes. **Revista Colombiana de Física**, v. 35, n. 1, p. 148–151, 2003.
- RAMOS, J. P. S. Redes neurais artificiais na classificação de frutos: Ce-nário bidimensional. SciELO Brasil, 2003.
- SANCHEZ, E. C. M. Controle por aprendizado acelerado e neuro-fuzzy de sistemas servo-hidráulicos de alta frequência. **Rio de Janeiro: PUC-Rio**, 2009.
- SANDOVAL, Z.; PRIETO, F. Procesamiento de imágenes para la clasificación de café cereza. Universidad Autónoma del Caribe, 2009.
- SANTOS, F. A.; PALMEIRA, E. S. Fuzzy numbers for characterizing the cocoa beans colors classes in the cut test. In: . [S.l.: s.n.], 2018.
- SANTOS, F. A.; PALMEIRA, E. S.; JESUS, G. Q. Color, structural and textural features for the classification of a cocoa beans image dataset using artificial neural network. In: . [S.l.: s.n.], 2018.
- SAVAKAR, D. Identification and classification of bulk fruits images using artificial neural networks. **International Journal of Engineering and Innovative Technology (IJEIT)**, v. 1, n. 3, p. 35–40, 2012.
- SHAHIN, M.; TOLLNER, E.; MCCLENDON, R.; ARABNIA, H. Apple classification based on surface bruises using image processing and neural networks. **Transactions of the ASAE**, American Society of Agricultural and Biological Engineers, v. 45, n. 5, p. 1619, 2002.
- SILVA, I. N. D.; SPATTI, H.; FLAUZINO, R. Redes neurais artificiais, curso prático. **para engenharia e ciências aplicadas/Ivan Nunes da Silva**, 2010.
- SULAIMAN, K. B.; YANG, T. A. Color characteristics of dried cocoa using shallow box fermentation technique. **Inter Scholar Sci Res Innov**, v. 9, p. 1277–1281, 2015.
- VALLE, R. R. **Ciência, tecnologia e manejo do cacau**. [S.l.]: Ilhéus, 2012.
- VERMA, B. Image processing techniques for grading & classification of rice. In: IEEE. **Computer and Communication Technology (ICCCT), 2010 International Conference on**. [S.l.], 2010. p. 220–223.
- WOOD, G. A. R.; LASS, R. **Cocoa**. [S.l.]: John Wiley & Sons, 2008.

- ZERNIKE, F.; MIDWINTER, J. E. **Applied nonlinear optics.** [S.l.]: Courier Corporation, 2006.
- ZHANG, Y.; PHILLIPS, P.; WANG, S.; JI, G.; YANG, J.; WU, J. Fruit classification by biogeography-based optimization and feedforward neural network. *Expert Systems*, v. 33, n. 3, p. 239–253, 2016. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/exsy.12146>>.